**НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ**
**«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ**
**ІМЕНІ ІГОРЯ СІКОРСЬКОГО»**
**Факультет програмних систем та прикладної математики**
**Кафедра прикладної математики**

# ЗВІТ З ПРАКТИКИ

**на тему:**
**«Модель для ідентифікації музичних інструментів в аудіозаписах на основі методів машинного навчання»**

Виконав: студент II курсу, групи КМ-51мп
Омельченко Іван Юрійович _____

Науковий керівник:
професор кафедри ПМА, д-р фіз.-мат. наук, професор
Лось Валерій Миколайович _____

Прийнято з оцінкою _____ балів

Члени комісії:
Маслянко Павло Павлович _____
Мазурик Роман Володимирович _____

Засвідчую, що в цьому звіті немає запозичень
із праць інших авторів без відповідних посилань.
Студент _____

Київ — 2026

# АНОТАЦІЯ

У звіті викладено результати переддипломної практики на тему «Модель для ідентифікації музичних інструментів в аудіозаписах на основі методів машинного навчання», що проходила на базі «_____», з «____» _____ 2026 року до «____» _____ 2026 року. У рамках практики поставлено задачу на дипломне проєктування, сформовано структуру дисертації, проведено аналіз існуючих рішень задачі розпізнавання музичних інструментів у звукових записах: методів на основі спектральних ознак та статистичних класифікаторів, згорткових нейронних мереж, гармонічних представлень звуку та методів розширення навчальних даних. Розроблено математичне забезпечення моделі згорткової нейронної мережі з музично обґрунтованими фільтрами, тембральні фільтри якої діють уздовж логарифмічної частотної осі, та методу її навчання на синтетичних сумішах записів. Під час практики розроблено програмне забезпечення мовою Python з використанням бібліотеки PyTorch.

Експериментальна перевірка на наборі даних IRMAS показала, що розроблена модель досягає макроусередненої F1-міри $0{,}524 \pm 0{,}004$ на тестовій вибірці багатоінструментних записів, що перевищує опубліковані результати відомих рішень. Зміст звіту із практики складається із документів, що були сформовані у ході виконання завдання на практику, а саме: заява на затвердження теми магістерської дисертації, формалізація постановки задачі, матриця сутностей, перша версія магістерської дисертації та тези доповіді на науковій конференції.

# ЗМІСТ

1 Остаточна тема магістерської дисертації . . . . . 4
2 Формалізація постановки задачі . . . . . 5
3 Матриця сутностей . . . . . 6
4 Перша версія магістерської дисертації . . . . . 10
5 Наукова стаття та апробація результатів . . . . . 73

# 1 ОСТАТОЧНА ТЕМА МАГІСТЕРСЬКОЇ ДИСЕРТАЦІЇ

Завідувачу кафедри прикладної математики
Данилу ТАВРОВУ

студента групи КМ-51мп
Омельченко Івана Юрійовича

ЗАЯВА

Для виконання магістерської дисертації прошу призначити мені наукового керівника — професора кафедри прикладної математики ФПМ, доктора фіз.-мат. наук, професора Лося В. М.

Орієнтовна тема моєї магістерської дисертації — «Модель для ідентифікації музичних інструментів в аудіозаписах на основі методів машинного навчання».

Формалізація постановки задачі дисертаційного дослідження додається.

17.06.2026

Іван ОМЕЛЬЧЕНКО 

«ПОГОДЖЕНО»

Тематика магістерської дисертації перебуває в сфері моїх наукових інтересів.

Валерій ЛОСЬ 

# 2 ФОРМАЛІЗАЦІЯ ПОСТАНОВКИ ЗАДАЧІ

ФОРМАЛЬНА ПОСТАНОВКА ЗАДАЧІ

**Тема:** «Модель для ідентифікації музичних інструментів в аудіозаписах на основі методів машинного навчання»

**Об’єкт дослідження:** Процес автоматичного розпізнавання музичних інструментів у багатоінструментних звукових записах на основі згорткових нейронних мереж.

**Предмет дослідження:** Моделі та методи побудови згорткових нейронних мереж для розпізнавання музичних інструментів, що враховують тембральну та часову будову звуку.

**Мета дослідження:** Підвищення точності розпізнавання музичних інструментів у багатоінструментних звукових записах шляхом розроблення моделі згорткової нейронної мережі з музично обґрунтованими фільтрами та методу її навчання на синтетичних сумішах записів.

**Методи дослідження:** Методи цифрової обробки звукових сигналів (коротковіконне перетворення Фур’є, мел-спектральний аналіз), методи навчання згорткових нейронних мереж, синтез багатоінструментних сумішей для розширення навчальних даних та порівняльний експериментальний аналіз моделей на стандартизованому наборі даних IRMAS з оцінюванням якості за макро- та мікроусередненою F1-мірою.

**Кінцевий результат:** Програмне забезпечення та модель згорткової нейронної мережі для автоматичного розпізнавання музичних інструментів у звукових записах, що забезпечує підвищення точності розпізнавання в багатоінструментних записах.

# 3 МАТРИЦЯ СУТНОСТЕЙ

Матриця Сутностей уніфікованої моделі Системи «Практика» (МССП) для формування поточного стану індивідуального бізнес-профіля наукових досліджень за темою МД.

Іван Омельченко, гр. КМ-51мп, 2-й курс 26/27.

Матрицю сутностей наведено на наступних сторінках.

# МАТРИЦЯ СУТНОСТЕЙ УНІФІКОВАНОЇ МОДЕЛІ СИСТЕМИ «ПРАКТИКА»

| № | Сутності та атрибути моделі системи «Практика» | Опис сутності уніфікованої моделі системи «Практика» |
|---|---|---|
| 1 | **№ за списком / ПІБ студента** | № 14 \| Омельченко Іван Юрійович |
| 2 | **Н/керівник ПІБ** | Лось Валерій Миколайович. Проф., д.ф.-м.н. |
| 3 | **Назва н/дослідження за темою МД** | «Модель для ідентифікації музичних інструментів в аудіозаписах на основі методів машинного навчання» |
| 4 | **ФПЗ: Об'єкт дослідження** | Процес автоматичного розпізнавання музичних інструментів у багатоінструментних звукових записах на основі згорткових нейронних мереж. |
| 5 | **ФПЗ: Предмет дослідження** | Моделі та методи побудови згорткових нейронних мереж для розпізнавання музичних інструментів, що враховують тембральну та часову будову звуку. |
| 6 | **ФПЗ: Мета дослідження** | Підвищення точності розпізнавання музичних інструментів у багатоінструментних звукових записах шляхом розроблення моделі згорткової нейронної мережі з музично обґрунтованими фільтрами та методу її навчання на синтетичних сумішах записів. |
| 7 | **ФПЗ: Кінцевий результат** | Програмне забезпечення та модель згорткової нейронної мережі для автоматичного розпізнавання музичних інструментів у звукових записах, що забезпечує підвищення точності розпізнавання в багатоінструментних записах. |
| 8 | **Клас. Ресурси/теоретичні: методи, моделі, алгоритми** | – цифрова обробка звукових сигналів: коротковіконне перетворення Фур'є, мел-шкала та банк мел-фільтрів, логарифмічна частотна вісь, часові похідні спектрограми;<br>– згорткові нейронні мережі; музично обґрунтовані форми фільтрів: вертикальні (тембральні) та горизонтальні (часові);<br>– гармонічна модель звуку (основний тон і обертони) та гармонічне накладання каналів;<br>– багатоміткова класифікація: незалежні сигмоїдні виходи, бінарна перехресна ентропія;<br>– розширення навчальних даних синтетичними багатоінструментними сумішами;<br>– агрегація оцінок ковзного вікна, вибір порогу рішення на перевірочній вибірці;<br>– метрики якості: точність, повнота, макро- та мікроусереднена F1-міра; статистичне оцінювання за кількома незалежними запусками. |
| 9 | **Клас. Ресурси/теоретичні: математичні дисципліни та їх інструменти** | – Лінійна алгебра (матриці, згортки, лінійна інтерполяція);<br>– Теорія ймовірностей та математична статистика (середнє, стандартне відхилення, оцінювання якості класифікаторів);<br>– Цифрова обробка сигналів і гармонічний аналіз (перетворення Фур'є, спектральний аналіз);<br>– Методи оптимізації (градієнтний спуск, метод Adam, функції втрат);<br>– Машинне навчання; Нейронні мережі; Інтелектуальний аналіз даних;<br>– Математичне моделювання; Системний аналіз. |
| 10 | **Клас. Ресурси/засоби** | – Python 3; PyTorch, torchaudio;<br>– NumPy, scikit-learn (метрики якості), soundfile (читання звукових файлів);<br>– Matplotlib (візуалізація спектрограм і результатів);<br>– Jupyter; Git / GitHub;<br>– обчислювальний ресурс: графічний процесор NVIDIA GeForce RTX 5070 Ti (16 ГБ);<br>– операційна система Windows 11, середовище розробки PyCharm;<br>– набір даних: IRMAS (11 класів інструментів, понад 6 тис. навчальних і 2874 тестові фрагменти). |
| 11 | **Клас. Процеси реалізації н/дослідження** | **Ітеративно-інкрементний процес (з елементами CRISP-DM).** Дорожня карта:<br>(1) огляд методів розпізнавання музичних інструментів і відомих результатів на наборі IRMAS, формалізація постановки задачі;<br>(2) підготовка даних, обчислення спектральних ознак, формування перевірочної вибірки без перетину записів з навчальною; |

| № | Сутності та атрибути моделі системи «Практика» | Опис сутності уніфікованої моделі системи «Практика» |
|---|---|---|
| | | (3) реалізація базових згорткових моделей і відтворення відомих архітектур;<br>(4) дослідження вхідних представлень і форм фільтрів, розроблення фільтрів на логарифмічній частотній осі та методу навчання на синтетичних сумішах;<br>(5) експериментальне оцінювання за кількома запусками, вибір порогу, аналіз внеску кожної складової моделі, порівняння з відомими результатами;<br>(6) оформлення результатів, висновків і тез доповіді. |
| 12 | **Клас. Бізнес-правила реалізації н/дослідження** | – Призначення: автоматичне визначення інструментального складу звукових записів.<br>– Область застосування: каталогізація та пошук у музичних колекціях, рекомендаційні системи, музичні архіви, навчальні застосунки.<br>– BR1 (вхідні дані): звукові записи довільної тривалості; перед обробкою приводяться до одного каналу з частотою дискретизації 22 050 Гц і нормалізуються за піковою амплітудою.<br>– BR2 (багатоміткова відповідь): для кожного запису видається множина присутніх інструментів (щонайменше один) з оцінками впевненості.<br>– BR3 (чесне оцінювання): перевірочна вибірка не містить фрагментів записів з навчальної; поріг рішення та інші налаштування не підбираються на тестовому наборі.<br>– BR4 (критерій якості): модель вважається кращою, якщо її середня макроусереднена F1-міра за п’ятьма запусками перевищує опубліковані результати відомих згорткових моделей на IRMAS.<br>– BR5 (продуктивність): розпізнавання одного запису тривалістю до 20 с — не довше 0,1 с на одному графічному процесорі.<br>– BR6 (відтворюваність): фіксація початкових значень генераторів випадкових чисел, конфігурації експериментів, відкритий набір даних.<br>– Календарний план: згідно з графіком виконання МД. |
| 13 | **Клас. Подія** | Події дорожньої карти: початок/кінець виконання класу завдань; отримання підготовлених даних та ознак; отримання першої версії моделі; отримання результатів експериментів; проміжні та підсумковий звіти з практики.<br>Апробація: подання тез доповіді на XIX науково-практичну конференцію «Прикладна математика та комп'ютинг» ПМК-2026 (до 11.11.2026), виступ на конференції (18–20.11.2026). |
| 14 | Користувач (дослідник / адміністратор музичної колекції) | Суб’єкт, який завантажує звукові записи, запускає розпізнавання та отримує перелік інструментів з оцінками впевненості; дослідник також запускає навчання й оцінювання моделей. |
| 15 | Набір даних D | $D = \{(x_i, y_i)\}$, $i = 1..N$ — набір IRMAS: навчальна частина (фрагменти по 3 с з одним переважаючим інструментом) і тестова частина (фрагменти 5–20 с з кількома інструментами); навчальна частина ділиться на навчальну та перевірочну вибірки за записами. |
| 16 | Звуковий фрагмент $x_i$ | Вхідний сигнал s(t): один канал, частота дискретизації 22 050 Гц, амплітуда нормалізована до [−1; 1]. |
| 17 | Множина класів інструментів C | C = {віолончель, кларнет, флейта, акустична гітара, електрогітара, орган, фортепіано, саксофон, труба, скрипка, голос}, $K = |C| = 11$. |
| 18 | Вектор міток $y_i$ | $y_i \in \{0, 1\}^K$ — багатоміткове позначення присутніх інструментів; у навчальних фрагментах одна одиниця, у тестових — одна або кілька. |
| 19 | Коротковіконне перетворення Фур’є | X(m, k) — спектр сигналу у вікні тривалістю 1024 відліки (≈46 мс) з кроком 512 відліків (≈23 мс); використовується амплітудний спектр $|X(m, k)|$. |
| 20 | Логарифмічна мел-спектрограма $M_i$ | $M_i = \log(\Phi \cdot |X|^2 + \varepsilon) \in R^{(128 \times T)}$: 128 мел-смуг у діапазоні 0–11 кГц, T = 130 кадрів для фрагмента 3 с; основне вхідне представлення моделі. |
| 21 | Часові похідні $\Delta M_i$, $\Delta^2 M_i$ | Перша та друга різниці спектрограми вздовж осі часу; відображають атаку та згасання нот. Подаються як додаткові вхідні канали. |
| 22 | Логарифмічна частотна вісь | Перерахунок мел-смуг на шкалу з 24 бінами на октаву (лінійна інтерполяція); на ній октава займає однакову кількість бінів на будь-якій висоті, на відміну від мел-шкали. |

| № | Сутності та атрибути моделі системи «Практика» | Опис сутності уніфікованої моделі системи «Практика» |
|---|---|---|
| 23 | Тембральні (вертикальні) фільтри | Згорткові ядра висотою дві октави на логарифмічній частотній осі та шириною один кадр; відображають спектральну обвідну — набір і співвідношення обертонів інструмента — незалежно від висоти ноти. |
| 24 | Часові (горизонтальні) фільтри | Згорткові ядра розміром 1×31 (≈0,7 с) на мел-спектрограмі; відображають часову обвідну звуку: атаку, стале звучання, згасання. |
| 25 | Модель розпізнавання f_θ | Згорткова нейронна мережа з параметрами θ: перший шар (квадратні, тембральні та часові фільтри) → три згорткові блоки → повнозв'язний класифікатор; $f_\theta(M) \to p \in [0, 1]^K$ (незалежні сигмоїдні виходи). |
| 26 | Гармонічна будова звуку | Основний тон $f_0$ і обертони $h \cdot f_0$ ($h = 2, 3, \ldots$). Досліджено гармонічне накладання каналів (зсув спектра на частоти обертонів) як альтернативне вхідне представлення. |
| 27 | Синтетична багатоінструментна суміш $\tilde{x}$ | $\tilde{x} = \log(\exp(M_a) + g \cdot \exp(M_b))$ — сума двох навчальних фрагментів у лінійній потужності з випадковою різницею гучності $g \in [-6; 6]$ дБ; мітка $\tilde{y} = y_a \vee y_b$. Застосовується до половини фрагментів кожного навчального пакета. |
| 28 | Функція втрат L | Бінарна перехресна ентропія $L = -\Sigma_k [y_k \cdot \log p_k + (1 - y_k) \cdot \log(1 - p_k)]$; мінімізується методом Adam з косинусним зменшенням кроку навчання. |
| 29 | Ковзне вікно | Розбиття тестового запису на вікна по 3 с з кроком 1,5 с; кожне вікно обробляється моделлю окремо. |
| 30 | Агрегація оцінок S | $S = \Sigma_w f_\theta(M_w)$ — сума ймовірностей по вікнах, нормована на максимум: $S \leftarrow S / \max_k S_k$ (найвпевненіший інструмент отримує 1). |
| 31 | Поріг рішення τ | Інструмент k вважається присутнім, якщо $S_k \geq \tau$; τ обирається на синтетичній багатоінструментній перевірочній вибірці. |
| 32 | Метрики якості | Точність, повнота та F1-міра для кожного класу; макро- та мікроусереднена F1-міра; результати подаються як середнє ± стандартне відхилення за п'ятьма запусками. |
| 33 | Модуль підготовки даних | Читання звукових файлів, перетворення в один канал, передискретизація, нормалізація, обчислення та кешування мел-спектрограм. |
| 34 | Модуль навчання | Формування пакетів, синтез багатоінструментних сумішей, навчання моделі, збереження контрольних точок і журналів. |
| 35 | Модуль розпізнавання | Обробка запису ковзним вікном, агрегація оцінок, застосування порогу; повертає перелік інструментів з оцінками впевненості. |
| 36 | Модуль оцінювання та порівняння | Розрахунок метрик на тестовому наборі для кожного запуску, порівняння архітектур, вибір порогу на перевірочній вибірці. |
| 37 | Сховище моделей та результатів | Збережені моделі (формат .pt), кеш спектрограм (.npy), конфігурації та журнали експериментів, таблиці результатів. |
| 38 | Архітектурні рівні застосунку | Рівень представлення (командний рядок, Jupyter); рівень бізнес-логіки (підготовка даних, навчання, розпізнавання, оцінювання); рівень доступу до даних. |
| 39 | Подія «Користувач завантажив звуковий запис» | Ініціює обчислення спектрограми та запуск модуля розпізнавання. |
| 40 | Подія «Завершено навчання моделі» | Ініціює оцінювання моделі на тестовому наборі та збереження результатів у сховище. |
| 41 | Формальна модель конвеєра | $s(t) \to \lvert X \rvert \to M \to [M, \Delta M, \Delta^2 M] \to f_\theta$ (по вікнах) $\to S \to \{k : S_k \geq \tau\}$ (множина інструментів). |
| 42 | Інші суттєві сутності та атрибути | – версіонування моделей і даних;<br>– відтворюваність експериментів (фіксовані початкові значення, конфігурації);<br>– порівняння з відтвореними відомими архітектурами за однаковою методикою. |

# 4 ПЕРША ВЕРСІЯ МАГІСТЕРСЬКОЇ ДИСЕРТАЦІЇ

Початок першої версії магістерської дисертації, оформленої згідно з ДСТУ, знаходиться на наступній сторінці.

**НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ**
**«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ**
**ІМЕНІ ІГОРЯ СІКОРСЬКОГО»**
**Факультет програмних систем та прикладної математики**
**Кафедра прикладної математики**

«До захисту допущено»
Завідувач кафедри
_____ Данило ТАВРОВ
«____» _____ 2026 р.

# Магістерська дисертація

**на здобуття ступеня магістра**
**за освітньо-науковою програмою «Наука про дані та математичне моделювання»**
**зі спеціальності «Прикладна математика»**
**на тему: «Модель для ідентифікації музичних інструментів в аудіозаписах на основі методів машинного навчання»**

Виконав:
студент групи КМ-51мп
Омельченко Іван Юрійович _____

Керівник:
професор кафедри ПМА, доктор фіз.-мат. наук
Лось Валерій Миколайович _____

Консультант з нормоконтролю:
старший викладач кафедри ПМА
Мальчиков Володимир Вікторович _____

Рецензент:
—
— _____

Засвідчую, що в цій магістерській дисертації
немає запозичень із праць інших авторів
без відповідних посилань.
Студент _____

Київ — 2026 року

**Національний технічний університет України**

**«Київський політехнічний інститут імені Ігоря Сікорського»**

**Факультет програмних систем та прикладної математики**

**Кафедра прикладної математики**

Рівень вищої освіти: другий (магістерський)

Спеціальність: 113 Прикладна математика

Освітньо-наукова програма «Наука про дані та математичне моделювання»

ЗАТВЕРДЖУЮ
Завідувач кафедри
_____ Данило ТАВРОВ
«____» _____ 2026 р.

**ЗАВДАННЯ**

**на магістерську дисертацію студенту**

Омельченку Івану Юрійовичу

1. Тема дисертації: «Модель для ідентифікації музичних інструментів в аудіозаписах на основі методів машинного навчання», керівник роботи Лось Валерій Миколайович, професор кафедри ПМА, доктор фіз.-мат. наук, затверджені наказом по університету «–» —- 2026 р. №1808-С.

2. Термін подання студентом дисертації: «–» —- 2026 р.

3. Вихідні дані до роботи: вихідними даними є звукові записи відкритого набору даних IRMAS, що містить навчальні фрагменти тривалістю 3 с з одним переважаючим інструментом і багатоінструментні тестові фрагменти тривалістю 5–20 с, позначені за 11 класами музичних інструментів, а також опубліковані результати відомих методів розпізнавання інструментів на цьому наборі.

4. Зміст роботи: огляд існуючих рішень з автоматичного розпізнавання музичних інструментів; розроблення математичного забезпечення моделі: часово-частотне представлення сигналу, музично обґрунтовані згорткові фільтри на логарифмічній частотній осі, синтез багатоінструментних сумішей, правило прийняття рішення та

вибір порогу; розроблення програмного забезпечення для підготовки даних, навчання, розпізнавання та оцінювання моделей; валідація результатів на наборі даних IRMAS і порівняння з існуючими рішеннями.

5. Перелік ілюстративного матеріалу: таблиця порівняння груп методів розпізнавання інструментів; таблиця архітектури розробленої моделі; схема архітектури програмного забезпечення; таблиці опису набору даних, результатів розробленої моделі, порівняння з існуючими рішеннями та аналізу внеску складових моделі.

6. Дата видачі завдання: «–» —- 2026 р.

Календарний план

| № з/п | Назва етапів виконання магістерської дисертації | Термін виконання етапів роботи | Примітка |
|---|---|---|---|
| 1 | Узгодження теми дисертації з науковим керівником, огляд наукових публікацій за тематикою дослідження | XX 2026 р. | |
| 2 | Аналіз існуючих рішень з автоматичного розпізнавання музичних інструментів, написання розділу огляду | XX 2026 р. | |
| 3 | Розроблення математичного забезпечення моделі розпізнавання музичних інструментів | XX 2026 р. | |
| 4 | Реалізація модулів підготовки даних і обчислення спектральних ознак | XX 2026 р. | |

| № з/п | Назва етапів виконання магістерської дисертації | Термін виконання етапів роботи | Примітка |
|---|---|---|---|
| 5 | Розроблення та навчання моделі згорткової нейронної мережі з музично обґрунтованими фільтрами | XX 2026 р. | |
| 6 | Валідація результатів, порівняння з існуючими рішеннями та аналіз внеску складових моделі | XX 2026 р. | |
| 7 | Написання розділів дисертації, підготовка висновків та списку використаних джерел | XX 2026 р. | |
| 8 | Остаточне оформлення дисертації, підготовка презентації | XX 2026 р. | |
| 9 | Подання повної версії магістерської дисертації | XX 2026 р. | |

Студент _____ Іван ОМЕЛЬЧЕНКО

Керівник роботи _____ Валерій ЛОСЬ

# РЕФЕРАТ

Магістерську дисертацію виконано на 62 аркушах, вона містить перелік посилань на використані джерела з 48 найменувань. У роботі наведено 1 рисунок та 13 таблиць.

**Актуальність теми.** Цифрові музичні колекції містять мільйони записів, для більшості з яких відсутній опис інструментального складу, потрібний для каталогізації, пошуку та рекомендацій. Ручне анотування потребує значних витрат часу, тому актуальним є автоматичне розпізнавання музичних інструментів у звукових записах. Найскладнішим є випадок багатоінструментних записів, де кілька інструментів звучать одночасно, а кожному запису може відповідати довільна підмножина інструментів. Існуючі згорткові моделі здебільшого використовують архітектури загального призначення, навчаються на записах з одним інструментом, а методики їх оцінювання описані неповно.

**Мета і задачі дослідження.** Метою роботи є підвищення точності розпізнавання музичних інструментів у багатоінструментних звукових записах шляхом розроблення моделі згорткової нейронної мережі з музично обґрунтованими фільтрами та методу її навчання на синтетичних сумішах записів.

Для досягнення мети розв’язано такі задачі:

а) проаналізовано існуючі методи автоматичного розпізнавання музичних інструментів, набори даних і методики оцінювання;

б) формалізовано задачу багатоміткового розпізнавання інструментів і розроблено математичну модель розпізнавання;

в) розроблено програмне забезпечення для підготовки даних, навчання, розпізнавання та оцінювання моделей;

г) розроблено відтворювану методику оцінювання та проведено валідацію розробленої моделі на стандартизованому наборі даних з порівнянням з існуючими рішеннями.

**Об’єктом дослідження** є процес автоматичного розпізнавання музичних інструментів у багатоінструментних звукових записах на основі згорткових нейронних мереж.

**Предметом дослідження** є моделі та методи побудови згорткових нейронних мереж для розпізнавання музичних інструментів, що враховують тембральну та часову будову звуку.

**Методи дослідження.** Методи цифрової обробки звукових сигналів (коротковіконне перетворення Фур'є, мел-спектральний аналіз), методи навчання згорткових нейронних мереж, синтез багатоінструментних сумішей для розширення навчальних даних та порівняльний експериментальний аналіз моделей на стандартизованому наборі даних IRMAS з оцінюванням якості за макро- та мікроусередненою F1-мірою.

**Наукова новизна.** Показано, що на мел-шкалі одна октава займає від 3 до 28 частотних смуг залежно від висоти, тому вертикальні (тембральні) фільтри сталої висоти охоплюють різні музичні інтервали; запропоновано виконувати такі фільтри на логарифмічній частотній осі, де кожен із них охоплює сталий музичний інтервал. Встановлено, що явне гармонічне представлення покращує розпізнавання при навчанні на записах з одним інструментом, але погіршує його при навчанні на синтетичних багатоінструментних сумішах.

**Практичне значення.** Розроблено програмне забезпечення для автоматичного розпізнавання музичних інструментів. Розроблена модель на наборі даних IRMAS досягає макроусередненої F1-міри $0{,}524 \pm 0{,}004$ та мікроусередненої $0{,}614 \pm 0{,}004$ (середнє за п'ятьма запусками), що перевищує опубліковані результати відомих згорткових моделей ($0{,}503$ та $0{,}516$) за 656 тис. параметрів. Результати можуть бути використані для автоматичної каталогізації та пошуку в музичних колекціях.

**Ключові слова:** розпізнавання музичних інструментів, багатоміткова класифікація, згорткові нейронні мережі, тембр, мел-спектрограма, логарифмічна частотна вісь, синтетичні суміші, F1-міра, IRMAS, музичний інформаційний пошук.

# ABSTRACT

The master's thesis comprises 62 pages and includes a list of 48 references. The work contains 1 figure and 13 tables.

**Relevance.** Digital music collections contain millions of recordings, most of which lack a description of their instrumentation, which is needed for cataloguing, search, and recommendation. Manual annotation is time-consuming, so automatic recognition of musical instruments in audio recordings is a relevant problem. The most difficult case is multi-instrument recordings, where several instruments sound simultaneously and each recording may correspond to an arbitrary subset of instruments. Existing convolutional models mostly rely on general-purpose architectures, are trained on single-instrument excerpts, and their evaluation protocols are often incompletely described.

**Purpose and objectives.** The aim of the work is to improve the accuracy of musical instrument recognition in multi-instrument audio recordings by developing a convolutional neural network model with musically motivated filters and a method for training it on synthetic mixtures of recordings.

To achieve this goal, the following tasks were solved:

a) existing methods of automatic musical instrument recognition, datasets, and evaluation protocols were analysed;

b) the multi-label instrument recognition problem was formalised and a mathematical model of the method was developed;

c) software for data preparation, training, recognition, and evaluation of models was developed;

d) a reproducible evaluation protocol was developed and the proposed model was validated on a standard dataset and compared with known solutions.

**Object of research** is the process of automatic recognition of musical instruments in multi-instrument audio recordings based on convolutional neural networks.

**Subject of research** is models and methods of building convolutional neural networks for musical instrument recognition that take into account the timbral and temporal structure of sound.

**Research methods.** Digital audio signal processing (short-time Fourier transform, mel

spectral analysis), training of convolutional neural networks, synthesis of multi-instrument mixtures for training data augmentation, and comparative experimental analysis of models on the standard IRMAS dataset using macro- and micro-averaged F1-score.

**Scientific novelty.** It is shown that on the mel scale one octave spans from 3 to 28 frequency bands depending on pitch, so vertical (timbral) filters of fixed height cover different musical intervals; it is proposed to apply such filters on a logarithmic frequency axis, where each of them covers a constant musical interval. It is established that an explicit harmonic representation improves recognition when training on single-instrument recordings but degrades it when training on synthetic multi-instrument mixtures.

**Practical value.** Software for automatic musical instrument recognition has been developed. On the IRMAS dataset the proposed model achieves a macro-averaged F1-score of $0.524 \pm 0.004$ and a micro-averaged F1-score of $0.614 \pm 0.004$ (mean over five runs), exceeding the published results of known convolutional models ($0.503$ and $0.516$) with 656 thousand parameters. The results can be used for automatic cataloguing and search in music collections.

**Keywords:** musical instrument recognition, multi-label classification, convolutional neural networks, timbre, mel spectrogram, logarithmic frequency axis, synthetic mixtures, F1-score, IRMAS, music information retrieval.

ЗМІСТ

Перелік скорочень, умовних позначень, термінів ..... 21
Вступ ..... 22
1 Огляд існуючих рішень з автоматичного розпізнавання музичних інструментів .. 25
1.1 Постановка задачі розпізнавання музичних інструментів ..... 25
1.2 Комерційні застосунки ..... 26
1.3 Набори даних і методики оцінювання ..... 27
1.4 Тембр і його акустичні ознаки ..... 27
1.5 Часово-частотне представлення звукового сигналу ..... 28
1.6 Методи на основі спектральних ознак та статистичних класифікаторів ..... 30
1.7 Згорткові нейронні мережі ..... 31
1.7.1 Мережі загального призначення ..... 31
1.7.2 Мережі з музично обґрунтованими фільтрами ..... 32
1.7.3 Моделі загального звукового аналізу ..... 32
1.7.4 Навчання для багатоміткової класифікації ..... 33
1.7.5 Розпізнавання записів довільної тривалості ..... 33
1.8 Гармонічні та частотно-інваріантні представлення ..... 34
1.9 Методи розширення навчальних даних ..... 35
1.10 Висновки до розділу ..... 35
2 Математичне забезпечення моделі розпізнавання музичних інструментів ..... 38
2.1 Формальна постановка задачі ..... 38
2.2 Вхідне представлення ..... 39
2.3 Нерівномірність октав на мел-шкалі ..... 39
2.4 Логарифмічна частотна вісь ..... 41
2.5 Перший шар з музично обґрунтованими фільтрами ..... 42
2.6 Архітектура моделі ..... 43
2.7 Гармонічне представлення ..... 44
2.8 Синтез багатоінструментних сумішей ..... 45
2.9 Навчання моделі ..... 46
2.10 Розпізнавання запису та вибір порогу рішення ..... 46
2.11 Математична модель розпізнавання ..... 47
2.12 Висновки до розділу ..... 50

3 Програмне забезпечення моделі розпізнавання музичних інструментів ..... 51
3.1 Призначення та вимоги ..... 51
3.2 Засоби реалізації ..... 52
3.3 Архітектура програмного забезпечення ..... 52
3.4 Організація обчислень ..... 53
3.5 Висновки до розділу ..... 54
4 Валідація результатів ..... 55
4.1 Опис навчальних і тестових даних ..... 55
4.2 Методика експериментів ..... 57
4.3 Метрики якості ..... 57
4.4 Вибір порогу рішення ..... 58
4.5 Аналіз отриманих результатів ..... 59
4.6 Порівняння з існуючими рішеннями ..... 61
4.7 Аналіз внеску складових моделі ..... 63
4.8 Висновки до розділу ..... 65
Висновки ..... 67
Перелік посилань ..... 68

# ПЕРЕЛІК СКОРОЧЕНЬ, УМОВНИХ ПОЗНАЧЕНЬ, ТЕРМІНІВ

F1-міра - середнє гармонійне точності та повноти класифікації

IRMAS - Instrument Recognition in Musical Audio Signals - набір даних для розпізнавання переважаючих музичних інструментів

Багатоміткова класифікація - задача, у якій кожному прикладу може відповідати довільна підмножина класів

Гармонічне накладання каналів - представлення, у якому копії спектра, розтягнуті на частоти обертонів, подаються як окремі вхідні канали

ЗНМ - згорткова нейронна мережа

Логарифмічна частотна вісь - частотна вісь, на якій кожна октава містить однакову кількість смуг

Мел-спектрограма - часово-частотне представлення сигналу, частотна вісь якого відповідає мел-шкалі

Синтетична суміш - штучний багатоінструментний приклад, отриманий додаванням навчальних фрагментів у лінійній потужності

Тембральні (вертикальні) фільтри - згорткові фільтри, що охоплюють широкий частотний діапазон в один момент часу і відображають спектральну обвідну звуку

Часові (горизонтальні) фільтри - згорткові фільтри, що охоплюють одну частотну смугу протягом певного часу і відображають часову обвідну звуку

# ВСТУП

**Актуальність теми.** Цифрові музичні колекції, потокові сервіси та архіви звукозаписів містять мільйони творів, для більшості з яких відсутній опис інструментального складу. Інформація про те, які інструменти звучать у записі, потрібна для каталогізації та пошуку музики, побудови рекомендаційних систем, музикознавчого аналізу й навчальних застосунків. Ручне анотування великих колекцій потребує значних витрат часу фахівців, тому актуальною є задача автоматичного розпізнавання музичних інструментів у звукових записах.

Найскладнішим є випадок багатоінструментних записів, у яких кілька інструментів звучать одночасно, їхні спектри накладаються, а набір присутніх інструментів заздалегідь невідомий. Сучасні підходи на основі згорткових нейронних мереж суттєво перевершили класичні методи, проте більшість із них використовують архітектури, запозичені з обробки зображень, і навчаються на записах з одним переважаючим інструментом, тоді як застосовуються до багатоінструментних. Крім того, методики оцінювання в опублікованих роботах часто не описані повністю або передбачають підбирання налаштувань на тестових даних, що ускладнює чесне порівняння методів. Отже, актуальним є розроблення моделі, яка враховує тембральну та часову будову звуку, навчається з урахуванням багатоінструментного характеру музики та оцінюється за відтворюваною методикою.

**Метою дослідження** є підвищення точності розпізнавання музичних інструментів у багатоінструментних звукових записах шляхом розроблення моделі згорткової нейронної мережі з музично обґрунтованими фільтрами та методу її навчання на синтетичних сумішах записів.

Для досягнення мети необхідно розв’язати такі *задачі*:

а) проаналізувати існуючі методи автоматичного розпізнавання музичних інструментів, набори даних і методики оцінювання;

б) формалізувати задачу багатоміткового розпізнавання інструментів та розробити математичну модель розпізнавання: часово-частотне представлення, музично обґрунтовані згорткові фільтри, синтез багатоінструментних сумішей, правило прийняття рішення;

в) розробити програмне забезпечення для підготовки даних, навчання, розпізнавання та оцінювання моделей;

г) розробити відтворювану методику оцінювання та провести валідацію розробленої моделі на стандартизованому наборі даних, порівнявши її з існуючими рішеннями та дослідивши внесок кожної складової моделі.

**Об'єктом дослідження** є процес автоматичного розпізнавання музичних інструментів у багатоінструментних звукових записах на основі згорткових нейронних мереж.

**Предметом дослідження** є моделі та методи побудови згорткових нейронних мереж для розпізнавання музичних інструментів, що враховують тембральну та часову будову звуку.

**Методи дослідження**: методи цифрової обробки звукових сигналів (коротковіконне перетворення Фур'є, мел-спектральний аналіз), методи навчання згорткових нейронних мереж, синтез багатоінструментних сумішей для розширення навчальних даних та порівняльний експериментальний аналіз моделей на стандартизованому наборі даних IRMAS з оцінюванням якості за макро- та мікроусередненою F1-мірою.

**Наукова новизна** одержаних результатів полягає в такому:

а) показано, що на мел-шкалі одна октава займає від трьох до двадцяти восьми частотних смуг залежно від висоти, через що вертикальні (тембральні) згорткові фільтри сталої висоти охоплюють різні музичні інтервали на різних частотах; запропоновано виконувати такі фільтри на логарифмічній частотній осі, де кожен фільтр охоплює однаковий музичний інтервал незалежно від висоти ноти;

б) встановлено, що користь явного гармонічного представлення (накладання каналів на частотах обертонів) залежить від умов навчання: воно покращує розпізнавання при навчанні на записах з одним інструментом, але погіршує його при навчанні на синтетичних багатоінструментних сумішах;

в) розроблено модель, яка поєднує музично обґрунтовані фільтри з навчанням на синтетичних сумішах і за суворішої методики оцінювання перевершує опубліковані результати відомих згорткових моделей на наборі даних IRMAS за меншої кількості параметрів.

**Практичне значення** одержаних результатів полягає в розробленому програмному забезпеченні, яке може бути використане для автоматичної каталогізації та пошуку в музичних колекціях, а також як основа для подальших

досліджень тембрового аналізу та змістового музичного пошуку.

# 1 ОГЛЯД ІСНУЮЧИХ РІШЕНЬ З АВТОМАТИЧНОГО РОЗПІЗНАВАННЯ МУЗИЧНИХ ІНСТРУМЕНТІВ

Автоматичне розпізнавання музичних інструментів є однією з базових задач музичного інформаційного пошуку. Вона полягає у визначенні за звуковим сигналом множини інструментів, що звучать у записі. У цьому розділі розглянуто постановку задачі, комерційні застосунки, набори даних і методики оцінювання, фізичну природу тембру, на якій ґрунтується розпізнавання, типовий спосіб часово-частотного представлення звукового сигналу, основні класи існуючих методів (від методів на основі спектральних ознак та статистичних класифікаторів до згорткових нейронних мереж) разом із загальними прийомами їх навчання та застосування, способи врахування гармонічної будови звуку та методи розширення навчальних даних. На основі огляду визначено недоліки існуючих рішень, які обґрунтовують напрям цієї роботи.

## 1.1 Постановка задачі розпізнавання музичних інструментів

Залежно від характеру вхідних даних розрізняють кілька варіантів задачі. Найпростішим є розпізнавання *ізольованих нот*, записаних окремо для кожного інструмента в контрольованих умовах. Складнішим є розпізнавання *сольних фрагментів*, де інструмент виконує музичну фразу з характерними прийомами гри. Найбільш наближеним до практики є розпізнавання інструментів у *багатоінструментних записах*, де кілька джерел звучать одночасно, їхні спектри перекриваються, а до сигналу додаються ударні, ефекти обробки та шуми запису [1, 2].

У багатоінструментному випадку задача природно формулюється як *багатоміткова класифікація*: кожному запису відповідає довільна підмножина з $K$ класів інструментів, а не один клас [3]. Часто розглядають її різновид: розпізнавання *переважаючих* інструментів, тобто тих, що чітко виділяються у звучанні, без вимоги

знайти всі інструменти суміші [4]. Особливістю найпоширенішого набору даних IRMAS є те, що навчальні фрагменти позначено одним переважаючим інструментом, а тестові одним або кількома. Отже, модель навчається на одноміткових даних, а оцінюється на багатоміткових, що є окремим джерелом складності.

## 1.2 Комерційні застосунки

Автоматичне розпізнавання інструментів уже використовується в комерційних продуктах, як правило, як частина ширших функцій. Сервіси автоматичного тегування музичних каталогів, зокрема Cyanite [5], визначають для записів набір ознак, серед яких жанр, настрій, темп та інструментальний склад; такі ознаки використовують звукозаписні компанії, видавці та бібліотеки музики для пошуку й добору творів. Подібні технології автоматичного тегування та пошуку розвивала компанія Musiio, яку у 2022 р. придбав сервіс SoundCloud для покращення пошуку музики [6].

У програмах для зведення звуку розпізнавання інструмента використовується для автоматичного налаштування обробки: модуль Track Assistant засобу iZotope Neutron визначає тип інструмента на доріжці (вокал, гітара, бас, ударні, фортепіано) і пропонує відповідні налаштування [7]. Близькою задачею є розділення готового запису на складові окремих інструментів, реалізоване, зокрема, у функції Stem Splitter програми Logic Pro, яка виділяє вокал, ударні, бас, гітару та фортепіано [8].

Спільною рисою комерційних рішень є закритість: методи, навчальні дані та показники якості, як правило, не публікуються, а набір розпізнаваних категорій обмежений. Частина рішень працює з окремими доріжками, на яких звучить один інструмент, а не з готовими багатоінструментними записами. Тому для порівняння методів використовують відкриті набори даних і опубліковані результати, розглянуті нижче.

## 1.3 Набори даних і методики оцінювання

*IRMAS* [4] є стандартним набором даних для розпізнавання переважаючих інструментів. Він містить 11 класів (віолончель, кларнет, флейта, акустична гітара, електрогітара, орган, фортепіано, саксофон, труба, скрипка, голос). Навчальна частина складається з 6705 фрагментів тривалістю 3 с, вирізаних з понад 2000 записів і позначених одним переважаючим інструментом; для частини фрагментів у назві файлу вказано жанр і наявність ударних. Тестова частина містить 2874 фрагменти тривалістю 5–20 с з одним або кількома позначеними інструментами. Детальніше набір описано в розділі 4.1.

*OpenMIC-2018* [9] містить близько 20 тис. десятисекундних фрагментів з 20 класами та частковою (слабкою) розміткою. *NSynth* [10] містить понад 300 тис. ізольованих нот і придатний переважно для задачі розпізнавання окремих звуків.

Для оцінювання багатоміткового розпізнавання використовують точність, повноту та F1-міру для кожного класу, а також їх макроусереднення (середнє за класами) та мікроусереднення (обчислення за об’єднанням усіх рішень) [11]. Макроусереднена міра однаково враховує всі класи, тому чутлива до якості розпізнавання рідкісних інструментів.

Аналіз опублікованих робіт показує, що методики оцінювання на IRMAS суттєво різняться і часто описані неповно: не завжди вказано спосіб формування перевірочної вибірки, правило вибору порогу та кількість незалежних запусків. Окремою проблемою є те, що навчальні фрагменти IRMAS вирізано з довших записів по кілька з кожного, тому випадковий поділ фрагментів на навчальну та перевірочну вибірки призводить до потрапляння частин одного запису в обидві вибірки і завищеної оцінки якості на перевірочних даних.

## 1.4 Тембр і його акустичні ознаки

Тембр є властивістю звуку, яка дає змогу розрізнити два звуки однакової висоти та гучності. З фізичного погляду тембр визначається кількома групами характеристик [12, 13].

*Гармонічна будова.* Звук більшості мелодичних інструментів є квазіперіодичним і містить основний тон частоти $f_0$ та обертони на частотах, близьких до $hf_0$, $h = 2, 3, \ldots$ Співвідношення амплітуд обертонів характерне для інструмента: так, у звуці кларнета в нижньому регістрі парні обертони значно слабші за непарні.

*Спектральна обвідна* є плавною функцією, що описує розподіл енергії за частотою незалежно від конкретної ноти. Вона формується резонансами корпусу інструмента чи голосового тракту (формантами).

*Часова обвідна* описує зміну амплітуди звуку в часі: швидкість атаки, наявність сталої фази та характер згасання. Наприклад, фортепіано та гітара мають різку атаку і поступове згасання, тоді як орган і смичкові інструменти можуть звучати рівно протягом тривалого часу.

*Шумові складові* (звуки дихання у духових інструментах, тертя смичка, удар молоточка) також несуть інформацію про джерело звуку.

Ці характеристики є основою як для побудови ознак тембру в класичних методах, так і для обґрунтування архітектурних рішень у нейромережевих моделях.

## 1.5 Часово-частотне представлення звукового сигналу

Більшість методів розпізнавання інструментів, як класичних, так і нейромережевих, працюють не безпосередньо зі звуковим сигналом, а з його часово-частотним представленням [12, 14]. Нижче описано типовий спосіб його обчислення; наведені значення параметрів поширені в роботах з розпізнавання інструментів [15].

*Попередня обробка.* Стереосигнал перетворюють на одноканальний усередненням каналів, передискретизують до частоти $f_s$ (типово 22 050 Гц) і нормують за піковою амплітудою [15]:

$$s(n) \leftarrow \frac{s(n)}{\max_n |s(n)|}. \tag{1.1}$$

*Коротковіконне перетворення Фур'є* [16, 12]. Сигнал ділять на кадри довжиною $N_w$ відліків з кроком $H$ і для кожного кадру, помноженого на віконну функцію $w(n)$, обчислюють спектр

$$X(m,k) = \sum_{n=0}^{N_w-1} s(n+mH)\, w(n)\, e^{-2\pi jkn/N_w}, \quad k = 0, \ldots, N_w/2, \tag{1.2}$$

де $m$ є номером кадру. При $f_s = 22050$ Гц, $N_w = 1024$ і $H = 512$ кадр триває близько 46 мс, а крок становить близько 23 мс.

*Мел-спектрограма.* Мел-шкала пов'язує частоту $f$ у герцах із суб'єктивно сприйнятою висотою [17]; використовується поширене наближення [18]:

$$\mu(f) = 2595 \log_{10}\!\left(1 + \frac{f}{700}\right). \tag{1.3}$$

Інтервал $[0;\ f_s/2]$ ділять на $F+1$ рівних відрізків на мел-шкалі, і центр $b$-ї смуги

$$\mu_b = b\,\Delta\mu, \quad \Delta\mu = \frac{\mu(f_s/2)}{F+1}, \quad b = 1, \ldots, F. \tag{1.4}$$

Банк трикутних фільтрів $\Phi \in \mathbb{R}^{F\times(N_w/2+1)}$, запропонований для обчислення мел-частотних ознак [19], підсумовує енергію спектра в кожній смузі, а логарифмічна мел-спектрограма

$$M(b,m) = \ln\!\left(\sum_{k} \Phi_{bk}\, |X(m,k)|^2 + \varepsilon\right), \tag{1.5}$$

де мала стала $\varepsilon$ (наприклад, $10^{-9}$) запобігає логарифму нуля.

*Часові похідні.* Для відображення часової обвідної, як і в класичних динамічних ознаках мовних сигналів [20], обчислюють першу та другу центральні різниці вздовж

осі часу:

$$\Delta M(b,m) = \frac{M(b,m+1) - M(b,m-1)}{2}, \qquad \Delta^2 M = \Delta(\Delta M). \tag{1.6}$$

Логарифмічна мел-спектрограма, іноді разом із похідними, є найпоширенішим входом згорткових моделей розпізнавання інструментів [15, 21].

## 1.6 Методи на основі спектральних ознак та статистичних класифікаторів

Перші системи розпізнавання інструментів ґрунтувалися на обчисленні набору ознак, що описують тембр, і подальшій класифікації за допомогою статистичних моделей [13]. Найпоширенішими ознаками є мел-частотні кепстральні коефіцієнти, що компактно описують спектральну обвідну [19], спектральні ознаки (центроїд, розкид, нахил, спад спектра), ознаки часової обвідної (тривалість атаки, швидкість згасання) та ознаки гармонічності. Великий перелік таких ознак систематизовано в роботі [22].

Як класифікатори використовували суміші гауссових розподілів, метод опорних векторів та метод $k$ найближчих сусідів [23, 24]. Для ізольованих нот і сольних фрагментів такі системи досягали високої точності [25], проте в багатоінструментних записах їхня якість різко знижується, оскільки ознаки, обчислені за всім сигналом, змішують внески кількох джерел. Для подолання цієї проблеми запропоновано ієрархічні класифікатори на основі автоматично побудованих таксономій ансамблів [1], зважування ознак з урахуванням ступеня їх перекриття [26], а також попереднє виділення переважаючого джерела методами розділення звуку [4].

Саме в роботі [4] разом із набором даних IRMAS запропоновано базовий метод на основі ознак та методу опорних векторів, що досягає макроусередненої F1-міри $0{,}432$ і мікроусередненої $0{,}503$ на тестовій частині набору [21]. Загальним недоліком методів цієї групи є залежність від експертного вибору ознак, які не завжди відображають відмінності між близькими за звучанням інструментами.

## 1.7 Згорткові нейронні мережі

Згорткові нейронні мережі навчаються виділяти ознаки безпосередньо з часово-частотного представлення сигналу [27, 28]. Як вхід зазвичай використовують логарифмічну мел-спектрограму, тобто двовимірну матрицю «частота × час», яку мережа обробляє подібно до зображення.

### 1.7.1 Мережі загального призначення

Найвідомішим рішенням для набору IRMAS є модель Хана, Кіма та Лі [15]. Вона складається з чотирьох блоків по дві згортки $3 \times 3$ з подальшим підвибором, глобального вибору максимуму та двох повнозв'язних шарів і має близько 1,45 млн параметрів. Модель навчається на фрагментах тривалістю 1 с, а під час розпізнавання тестовий запис обробляється ковзним вікном, оцінки вікон підсумовуються та нормуються на максимум, після чого застосовується поріг. Автори повідомляють макроусереднену F1-міру $0{,}503$ та мікроусереднену $0{,}602$. Водночас, згідно з текстом роботи, тривалість вікна, спосіб агрегації та поріг обирались за найкращим значенням F1-міри, а окремого опису перевірочної вибірки для цього вибору не наведено, що робить результат дещо оптимістичним.

Інші роботи досліджували навчання безпосередньо на звуковому сигналі [29], спіральне представлення висоти тону, що враховує октавну подібність [30], спільне розпізнавання інструментів і висоти тону на рівні окремих кадрів [31], а також механізми уваги для розпізнавання за слабкими мітками на наборі OpenMIC-2018 [32, 9].

### 1.7.2 Мережі з музично обґрунтованими фільтрами

Пояснення роботи мереж загального призначення ускладнене тим, що квадратні фільтри не мають очевидного акустичного змісту. Понс та співавтори [21] запропонували проєктувати форму фільтрів першого шару відповідно до будови тембру. *Вертикальні* фільтри охоплюють велику частину частотної осі в межах одного або кількох кадрів і відображають спектральну обвідну. Фільтри малої висоти та більшої ширини відображають часову обвідну. У запропонованій ними моделі для IRMAS перший шар містить фільтри висотою $5$ і $80$ смуг (із $96$) різної ширини, після нього виконується підвибір майже за всією частотною віссю, далі два згорткові шари та повнозв’язний шар. Модель має близько 743 тис. параметрів і досягає макроусередненої F1-міри $0{,}516$ та мікроусередненої $0{,}589$, тобто кращого за модель [15] значення макроусередненої міри за вдвічі меншої кількості параметрів. Як і в роботі [15], поріг рішення ($0{,}2$) та протокол вибору моделі детально не обґрунтовано, а кількість незалежних запусків не вказано.

Висоту таких фільтрів задають у частотних смугах мел-спектрограми. Як буде показано в розділі 2, через нерівномірність мел-шкали фільтр сталої висоти охоплює різні музичні інтервали на різних частотах, що суперечить ідеї фільтра, який описує тембр незалежно від висоти ноти.

### 1.7.3 Моделі загального звукового аналізу

Окремий напрям становлять моделі, попередньо навчені на великих наборах загальних звуків, зокрема AudioSet [33, 34, 35], з подальшим донавчанням на цільовій задачі. Такі моделі зазвичай мають десятки мільйонів параметрів і досягають вищої якості, проте потребують значних обчислювальних ресурсів, а їхні результати важко зіставляти з моделями, навченими лише на цільовому наборі. Тому в цій роботі розглядаються лише моделі, які навчаються з нуля на наборі IRMAS без залучення зовнішніх даних.

### 1.7.4 Навчання для багатоміткової класифікації

Для багатоміткової постановки вихідний шар мережі містить $K$ незалежних сигмоїдних виходів $p_k = \sigma(z_k) = 1/(1 + e^{-z_k})$, кожен з яких оцінює ймовірність присутності відповідного інструмента [3, 28]. Параметри мережі $\theta$ визначають мінімізацією бінарної перехресної ентропії, усередненої за класами та прикладами пакета з $B$ прикладів:

$$\mathcal{L}(\theta) = -\frac{1}{BK} \sum_{i=1}^{B} \sum_{k=1}^{K} \Big[ y_{ik} \ln p_{ik} + (1 - y_{ik}) \ln(1 - p_{ik}) \Big]. \tag{1.7}$$

Для мінімізації поширено використовують метод Adam [36], а крок навчання поступово зменшують, зокрема за косинусним законом [37]:

$$\eta_e = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min}) \left(1 + \cos \frac{\pi e}{E}\right), \tag{1.8}$$

де $e$ позначає номер епохи, $E$ задає кількість епох, а $\eta_0$ і $\eta_{\min}$ є початковим і кінцевим кроком. Для стабілізації навчання застосовують пакетну нормалізацію [38], а для регуляризації проріджування, тобто випадкове вимикання каналів і нейронів під час навчання [39].

### 1.7.5 Розпізнавання записів довільної тривалості

Моделі навчають на фрагментах фіксованої тривалості (як правило, 1–3 с), тоді як записи, що аналізуються, довші. У роботі [15] запропоновано обробляти запис ковзним вікном довжиною $T$ кадрів з кроком $T/2$, обчислювати для вікон $w = 1, \ldots, W$ ймовірності $\mathbf{p}^{(w)}$ та агрегувати їх підсумовуванням з нормуванням на

максимум:

$$S_k = \sum_{w=1}^{W} p_k^{(w)}, \qquad \bar{S}_k = \frac{S_k}{\max_j S_j}. \tag{1.9}$$

Нормування гарантує, що найвпевненіше розпізнаний інструмент отримує оцінку 1. Остаточне рішення приймається за порогом $\tau$:

$$\hat{y}_k = \begin{cases} 1, & \bar{S}_k \geqslant \tau, \\ 0, & \bar{S}_k < \tau, \end{cases} \qquad k = 1, \ldots, K. \tag{1.10}$$

Автори [15] порівнювали також усереднення оцінок без нормування й обрали нормоване підсумовування з порогом $0{,}5$; у роботі [21] оцінки усереднюються, а поріг становить $0{,}2$.

## 1.8 Гармонічні та частотно-інваріантні представлення

Мел-спектрограма має нерівномірну частотну роздільність: смуги рівномірно розташовані на психоакустичній мел-шкалі [17], яка є майже лінійною нижче 1 кГц і майже логарифмічною вище. Альтернативою є перетворення зі сталою добротністю [40], у якому кожна октава містить однакову кількість частотних смуг. На такій осі зміна висоти ноти відповідає зсуву спектра на сталу кількість смуг, а відстані між обертонами не залежать від висоти основного тону.

Цю властивість використовують для явного врахування гармонічної будови звуку. У гармонічному представленні [41] кілька копій спектра, розтягнутих у $h$ разів по частоті, накладаються як канали входу мережі, так що в одній точці згортка «бачить» енергію основного тону та обертонів. У роботі [42] запропоновано навчувані гармонічні фільтри. Інший підхід полягає в розділенні сигналу на гармонічну та ударну складові методом медіанної фільтрації [43], що дає змогу зменшити вплив ударних інструментів, які в наборі IRMAS не розмічаються. Ці

представлення здебільшого досліджувались для оцінювання висоти тону та загальної класифікації звуків, а їхня ефективність для розпізнавання інструментів у багатоінструментних записах залишається недостатньо вивченою.

## 1.9 Методи розширення навчальних даних

Набори даних для розпізнавання інструментів невеликі за обсягом, тому поширеним прийомом є штучне розширення навчальної вибірки. Для звукових даних застосовують зміну висоти та темпу, додавання шуму, маскування частотних смуг і часових інтервалів [44, 45]. Метод змішування прикладів [46] формує лінійні комбінації пар прикладів і їхніх міток, проте для звуку така комбінація логарифмічних спектрограм не відповідає фізичному додаванню сигналів, а дробові мітки не відповідають багатомітковій постановці.

Для задачі, в якій навчальні дані містять один переважаючий інструмент, а тестові кілька, природним є створення штучних багатоінструментних сумішей з навчальних записів. Такий підхід досліджувався в роботі [47], де показано його користь для класифікації інструментів у поліфонічній музиці. Водночас питання про те, як синтетичні суміші взаємодіють з архітектурними рішеннями, зокрема з гармонічними представленнями, залишається відкритим.

## 1.10 Висновки до розділу

У розділі розглянуто існуючі рішення задачі автоматичного розпізнавання музичних інструментів. Узагальнене порівняння основних груп методів наведено в таблиці 1.1.

Таблиця 1.1 – Порівняння груп методів розпізнавання музичних інструментів

| Група методів | Переваги | Недоліки | Макро-F1 на IRMAS |
|---|---|---|---|
| Спектральні ознаки та статистичні класифікатори [4] | Інтерпретованість, невеликі вимоги до обчислень | Залежність від вибору ознак, низька якість у сумішах | 0,432 |
| Згорткові мережі загального призначення [15] | Автоматичне виділення ознак | Велика кількість параметрів, відсутність акустичного змісту фільтрів | 0,503 |
| Мережі з музично обґрунтованими фільтрами [21] | Менша кількість параметрів, інтерпретованість фільтрів | Висота фільтрів задана в мел-смугах, а не в музичних інтервалах | 0,516 |
| Моделі загального звукового аналізу [35] | Висока якість завдяки великим зовнішнім даним | Десятки мільйонів параметрів, складність порівняння | - |
| Комерційні сервіси [5, 7] | Готові до використання, працюють з великими каталогами | Закриті методи та показники якості, обмежений набір категорій | - |

За результатами огляду виявлено такі недоліки існуючих рішень:

а) вертикальні фільтри, що мають описувати тембр, задаються сталою висотою в смугах мел-спектрограми і через нерівномірність мел-шкали охоплюють різні музичні інтервали на різних частотах;

б) моделі навчаються на записах з одним переважаючим інструментом, а застосовуються до багатоінструментних, причому цю розбіжність, як правило, не компенсують на етапі навчання;

в) вплив явних гармонічних представлень на розпізнавання інструментів у сумішах, особливо в поєднанні з розширенням даних, недостатньо досліджено;

г) методики оцінювання на наборі IRMAS неоднорідні: поріг рішення іноді обирають за результатами на тестових даних, кількість запусків не вказують, а випадковий поділ фрагментів спричиняє перетин навчальної та перевірочної вибірок.

Отже, у роботі доцільно розробити модель згорткової нейронної мережі, у якій тембральні фільтри охоплюють сталі музичні інтервали, навчати її на синтетичних багатоінструментних сумішах, дослідити роль гармонічних представлень та оцінювати результати за відтворюваною методикою без використання тестових даних для вибору налаштувань.

# 2 МАТЕМАТИЧНЕ ЗАБЕЗПЕЧЕННЯ МОДЕЛІ РОЗПІЗНАВАННЯ МУЗИЧНИХ ІНСТРУМЕНТІВ

У розділі наведено формальну постановку задачі та математичне забезпечення розробленої моделі. Загальновідомі складові (обчислення часово-частотного представлення, навчання згорткових мереж для багатоміткової класифікації, агрегація оцінок ковзного вікна) описано в розділі 1; тут наведено лише їх параметри. Основну увагу приділено нерівномірності октав на мел-шкалі та переходу до логарифмічної частотної осі для тембральних фільтрів, архітектурі моделі, методу синтезу багатоінструментних сумішей, способу вибору порогу рішення та зведенню всіх складових у єдину математичну модель. Окремо розглянуто гармонічне представлення, яке досліджувалось як альтернативний спосіб врахування будови звуку.

## 2.1 Формальна постановка задачі

Нехай $\mathcal{C} = \{c_1, \ldots, c_K\}$ є множиною класів інструментів, $K = 11$. Набір даних

$$\mathcal{D} = \{(s_i, \mathbf{y}_i)\}_{i=1}^{N} \tag{2.1}$$

складається зі звукових записів $s_i(t)$ та векторів міток $\mathbf{y}_i \in \{0,1\}^K$, де $y_{ik} = 1$, якщо інструмент $c_k$ присутній у записі $s_i$. У навчальній частині кожен вектор містить рівно одну одиницю, у тестовій одну або більше.

Потрібно побудувати відображення

$$\hat{\mathbf{y}} = \mathcal{R}(s), \quad \mathcal{R} : s \mapsto \{0,1\}^K, \tag{2.2}$$

яке за записом довільної тривалості визначає множину присутніх інструментів. Відображення $\mathcal{R}$ складається з обчислення часово-частотного представлення, оцінювання ймовірностей присутності інструментів моделлю $f_\theta$ з параметрами $\theta$ на фрагментах запису та правила прийняття рішення. Параметри $\theta$ визначаються мінімізацією функції втрат на навчальній вибірці, а якість $\mathcal{R}$ оцінюється макроусередненою F1-мірою на тестовій вибірці (розділ 4.3).

## 2.2 Вхідне представлення

Як вхід моделі використовується логарифмічна мел-спектрограма та її часові похідні (розділ 1.5). Параметри перетворення обрано такими самими, як у роботі [15], що забезпечує зіставність результатів: сигнал приводиться до одного каналу та частоти дискретизації $f_s = 22050$ Гц і нормується за піковою амплітудою; довжина вікна $N_w = 1024$ відліки, крок $H = 512$ відліків, кількість мел-смуг $F = 128$, звідки крок мел-шкали (1.4) $\Delta\mu \approx 24{,}6$ мел. Фрагмент тривалістю 3 с відповідає $T = 130$ кадрам, тож вхідними даними моделі є тензор

$$\mathbf{X} = [M, \Delta M, \Delta^2 M] \in \mathbb{R}^{3\times 128\times 130}. \tag{2.3}$$

## 2.3 Нерівномірність октав на мел-шкалі

Із (1.3)–(1.4) випливає, що номер смуги, яка відповідає частоті $f$, дорівнює $b(f) = \mu(f)/\Delta\mu$. Тоді кількість смуг, що припадає на одну октаву $[f;\, 2f]$, становить

$$N_{\text{окт}}(f) = b(2f) - b(f) = \frac{2595}{\Delta\mu}\log_{10}\frac{700+2f}{700+f}. \tag{2.4}$$

При $f \ll 700$ Гц $N_{\text{окт}}(f) \approx 1{,}61 f/\Delta\mu$ і прямує до нуля, а при $f \gg 700$ Гц прямує до $2595\log_{10}2/\Delta\mu \approx 31{,}7$. Значення для частот, що відповідають нотам ля різних октав,

наведено в таблиці 2.1.

Таблиця 2.1 – Кількість мел-смуг в одній октаві ($F = 128$, $f_s = 22050$ Гц)

| Октава, Гц | Мел-смуг на октаву |
|---|---|
| 55–110 | 3 |
| 110–220 | 5 |
| 220–440 | 10 |
| 440–880 | 15 |
| 880–1760 | 21 |
| 1760–3520 | 24 |
| 3520–7040 | 28 |

Отже, вертикальний фільтр сталої висоти, наприклад 31 смуга, у нижньому регістрі охоплює близько п’яти октав, а у верхньому лише близько однієї. Набір обертонів одного й того самого інструмента на різних нотах відображається на мел-спектрограмі по-різному, і фільтр, навчений розпізнавати тембр на одній висоті, не переноситься на іншу. Ця властивість обґрунтовує перехід до логарифмічної частотної осі.

## 2.4 Логарифмічна частотна вісь

Логарифмічна вісь задається нижньою частотою $f_{\min} = 32{,}7$ Гц (нота до контроктави) та кількістю смуг на октаву $\beta$:

$$\varphi_\ell = f_{\min} \cdot 2^{\ell/\beta}, \quad \ell = 0, \ldots, L-1, \tag{2.5}$$

де $L$ обирається так, щоб $\varphi_{L-1}$ не перевищувала центру найвищої мел-смуги. Мел-спектрограма переноситься на цю вісь лінійною інтерполяцією. Позиція частоти $\varphi_\ell$ на мел-осі $p_\ell = \mu(\varphi_\ell)/\Delta\mu$; позначивши $b_\ell = \lfloor p_\ell \rfloor$, $\alpha_\ell = p_\ell - b_\ell$, отримуємо

$$\widetilde{M}(\ell, m) = (1 - \alpha_\ell)\, M(b_\ell, m) + \alpha_\ell\, M(b_\ell + 1, m), \tag{2.6}$$

або в матричному вигляді $\widetilde{M} = PM$, де $P \in \mathbb{R}^{L \times F}$ є розрідженою матрицею інтерполяції з двома ненульовими елементами в кожному рядку. Аналогічно будується матриця зворотного перенесення $Q \in \mathbb{R}^{F \times L}$ з логарифмічної осі на мел-сітку.

На логарифмічній осі октава займає рівно $\beta$ смуг на будь-якій висоті. Значення $\beta$ доцільно узгодити з роздільністю мел-шкали: якщо $\beta$ значно менше за кількість мел-смуг на октаву, перенесення на логарифмічну вісь втрачає інформацію, а якщо значно більше, лише дублює сусідні значення. Згідно з таблицею 2.1, до 3,5 кГц, де розташовані основні тони інструментів і нижні обертони, мел-шкала містить не більше 24 смуг на октаву; вище ця кількість зростає лише до 28. Перевірка на гармонічному тоні показала, що середня похибка перетворення $QPM - M$ у діапазоні 300 Гц–2 кГц становить $1{,}1$ (у логарифмічних одиницях) при $\beta = 12$ і $0{,}5$ при $\beta = 24$, тому в роботі обрано $\beta = 24$, що дає $L = 201$ смугу.

Розглянемо, як на цій осі відображається зміна висоти ноти. Нехай звук ідеалізовано описано як суму обертонів з амплітудами $a_h$, що не залежать від висоти

основного тону $f_0$. Обертон $hf_0$ розташований у смузі

$$\ell_h = \beta \log_2 \frac{hf_0}{f_{\min}} = \beta \log_2 h + \beta \log_2 \frac{f_0}{f_{\min}}. \tag{2.7}$$

Перший доданок не залежить від $f_0$, тому взаємне розташування обертонів є сталим. Підвищення ноти на $d$ півтонів, тобто заміна $f_0 \to f_0 \cdot 2^{d/12}$, додає до всіх $\ell_h$ однакову величину $\beta d/12$, тобто зсуває все представлення звуку без зміни форми. Оскільки згортка комутує зі зсувом, відгук згорткового фільтра також лише зсувається на ту саму величину. Отже, фільтр, який навчився відповідати певному набору обертонів, реагує на нього однаково на будь-якій висоті. На мел-осі, згідно з (2.4), зсув різний для різних обертонів, і ця властивість не виконується.

## 2.5 Перший шар з музично обґрунтованими фільтрами

Перший згортковий шар моделі містить три паралельні групи фільтрів, форма яких відповідає складовим тембру (розділ 1.4):

$$\mathbf{Z} = \Big[ \underbrace{W_{\square} * \mathbf{X}}_{16\text{ каналів}},\ \underbrace{Q\left(W_{\downarrow} * P\mathbf{X}\right)}_{8\text{ каналів}},\ \underbrace{W_{\rightarrow} * \mathbf{X}}_{8\text{ каналів}} \Big] \in \mathbb{R}^{32\times 128\times 130}, \tag{2.8}$$

де $*$ позначає двовимірну згортку з доповненням нулями, $P\mathbf{X}$ та $Q(\cdot)$ означають застосування матриць $P$ і $Q$ до кожного каналу вздовж частотної осі;

– $W_{\square}$: 16 квадратних фільтрів розміром $3 \times 3$ для локальних деталей;

– $W_{\downarrow}$: 8 вертикальних (тембральних) фільтрів розміром $(2\beta+1)\times 1 = 49 \times 1$, що на логарифмічній осі охоплюють рівно дві октави і відображають спектральну обвідну;

– $W_{\rightarrow}$: 8 горизонтальних (часових) фільтрів розміром $1 \times 31$ ($\approx$ 0,7 с), що відображають атаку та згасання.

Ідея поділу першого шару на фільтри різної форми запропонована в [21]. Відмінність розробленого рішення полягає в тому, що тембральні фільтри виконуються на логарифмічній осі і, як показано в розділі 2.4, описують тембр

однаково для всіх висот, після чого їхні відгуки переносяться назад на мел-сітку й об’єднуються з іншими групами фільтрів.

## 2.6 Архітектура моделі

Модель $f_\theta$ складається з чотирьох згорткових блоків і повнозв’язного класифікатора (табл. 2.2). Кожен блок містить згортку, пакетну нормалізацію та випрямлену лінійну функцію активації $\max(0, z)$ (далі випрямлення). Після перших трьох блоків виконується підвибір максимуму $2 \times 2$. Останній блок завершується адаптивним підвибором максимуму до розміру $2 \times 2$: на відміну від усереднення, вибір максимуму зберігає сильну реакцію на інструмент, що звучить лише частину фрагмента. Для регуляризації використовується проріджування (розділ 1.7.4).

Таблиця 2.2 – Архітектура розробленої моделі

| Шар | Операції | Розмір виходу |
|---|---|---|
| Вхід | $[M, \Delta M, \Delta^2 M]$ | $3 \times 128 \times 130$ |
| Блок 1 | перший шар (2.8), нормалізація, випрямлення, підвибір | $32 \times 64 \times 65$ |
| Блок 2 | згортка $3 \times 3$, нормалізація, випрямлення, підвибір | $64 \times 32 \times 32$ |
| Блок 3 | згортка $3 \times 3$, нормалізація, випрямлення, підвибір | $128 \times 16 \times 16$ |
| Блок 4 | згортка $3 \times 3$, нормалізація, випрямлення, адаптивний максимум, проріджування $0{,}25$ | $256 \times 2 \times 2$ |
| Класифікатор | повнозв’язні шари $1024 \to 256 \to 11$, проріджування $0{,}3$ | 11 |
| Вихід | сигмоїда $\sigma(z) = 1/(1 + e^{-z})$ для кожного класу | 11 |

Вихід моделі $\mathbf{p} = f_\theta(\mathbf{X}) \in [0; 1]^K$ містить незалежні ймовірності присутності

кожного інструмента, що відповідає багатомітковій постановці. Загальна кількість параметрів становить 656 091.

## 2.7 Гармонічне представлення

Як альтернативний спосіб врахування будови звуку досліджувалось гармонічне накладання каналів [41]. Для мел-смуги $b$ з центральною частотою $f_b$ і номера обертона $h$ формується канал

$$H_h(b, m) = M\big(\, b^*(h f_b), m\big), \tag{2.9}$$

де $b^*(f)$ означає дробову позицію частоти $f$ на мел-осі, а значення між смугами обчислюється лінійною інтерполяцією. Досліджувались набори $h \in \{1, 2, 4, 8\}$ (октави основного тону) та $h \in \{1, \ldots, 5\}$ (основний тон і чотири обертони). У точці $(b, m)$ канали $H_h$ містять енергію на частотах відповідних обертонів, тож уже перший шар згортки може виявити гармонічний ряд. Розглядався також канал «м'якого мінімуму» за обертонами

$$G(b, m) = -\kappa \ln \sum_{h=1}^{4} \exp\!\left(-\frac{H_h(b,m)}{\kappa}\right), \qquad \kappa = 1, \tag{2.10}$$

який є високим лише там, де присутні всі обертони ряду.

Для одноінструментного сигналу ці представлення однозначні. У суміші ж енергія на частоті $h f_b$ може належати іншому інструменту, і гармонічні канали отримують хибні підтвердження. Як показано в розділі 4.7, при навчанні на синтетичних сумішах такі представлення погіршують якість, тому в остаточну модель їх не включено.

## 2.8 Синтез багатоінструментних сумішей

Щоб зменшити розбіжність між навчальними (один інструмент) і тестовими (кілька інструментів) даними, під час навчання формуються синтетичні суміші. Для пакета з $B$ фрагментів кожен фрагмент $i$ з імовірністю $q = 0{,}5$ змішується з фрагментом $\pi(i)$, де $\pi$ є випадковою перестановкою. Оскільки спектрограми логарифмічні, а сигнали різних джерел додаються в лінійній потужності, суміш обчислюється як

$$\widetilde{M}_i = \ln\!\left(e^{M_i} + g_i\, e^{M_{\pi(i)}}\right), \qquad g_i = 10^{\gamma_i/10},\ \ \gamma_i \sim U[-6;\,6] \text{ дБ}, \tag{2.11}$$

що обчислюється в чисельно стійкій формі $\ln(e^a + e^b) = \max(a,b) + \ln\!\left(1 + e^{-|a-b|}\right)$. Множник $g_i$ задає випадкову різницю гучностей джерел. Вектор міток суміші є об'єднанням міток:

$$\widetilde{\mathbf{y}}_i = \mathbf{y}_i \vee \mathbf{y}_{\pi(i)}, \qquad \widetilde{y}_{ik} = \max\left(y_{ik}, y_{\pi(i)k}\right). \tag{2.12}$$

Часові похідні обчислюються вже для суміші. На відміну від методу змішування прикладів [46], вираз (2.11) відповідає фізичному додаванню звуків, а мітки залишаються двійковими.

Оскільки $\ln(e^a + e^b) \approx \max(a, b)$ при $|a - b| \gg 1$, у кожній частотно-часовій точці суміші переважає сильніше джерело, що узгоджується з властивістю маскування в реальних записах. При кожному проході по навчальній вибірці суміші формуються заново, тож модель бачить нові комбінації інструментів і повільніше перенавчається. Це обґрунтовує використання більшої кількості епох навчання, ніж без змішування (розділ 4.7).

## 2.9 Навчання моделі

Модель навчається мінімізацією бінарної перехресної ентропії (1.7), у якій замість вихідних міток використовуються мітки сумішей $\widetilde{\mathbf{y}}_i$. Для мінімізації застосовується метод Adam з косинусним зменшенням кроку навчання (1.8) (розділ 1.7.4) з параметрами $E = 100$ епох, $\eta_0 = 10^{-3}$, $\eta_{\min} = 10^{-5}$ та розміром пакета $B = 32$.

## 2.10 Розпізнавання запису та вибір порогу рішення

Запис довільної тривалості обробляється ковзним вікном довжиною $T = 130$ кадрів (3 с) з кроком $T/2$, а оцінки вікон агрегуються нормованим підсумовуванням (1.9); рішення приймається правилом (1.10) (розділ 1.7.5).

Поріг $\tau$ не можна обирати за результатами на тестовій вибірці, а перевірочна вибірка, складена з навчальних фрагментів, містить по одному інструменту і тому схиляє до вибору порогу, що пригнічує другорядні інструменти. Тому поріг обирається на *синтетичній багатоінструментній перевірочній вибірці* $\widetilde{\mathcal{V}}$: кожен перевірочний фрагмент змішується за формулою (2.11) з $r - 1$ фрагментами інших записів, де кількість джерел $r \in \{1, 2, 3\}$ обирається рівноймовірно, а генератор випадкових чисел фіксовано. Поріг

$$\tau^{*} = \arg\max_{\tau \in \mathcal{T}} \; \frac{1}{R} \sum_{\rho=1}^{R} \mathrm{F1}_{\text{макро}}\big(\widetilde{\mathcal{V}};\, f_{\theta_\rho}, \tau\big), \tag{2.13}$$

де $\mathcal{T} = \{0{,}30; 0{,}35; \ldots; 0{,}80\}$, а усереднення ведеться за $R$ незалежними запусками навчання.

## 2.11 Математична модель розпізнавання

Зведемо описані вище складові в єдину математичну модель, яка складається з чотирьох частин: представлення сигналу, моделі оцінювання ймовірностей, навчання та правила розпізнавання запису.

*Представлення сигналу.* Фрагмент $s$ тривалістю 3 с перетворюється на тензор

$$\mathbf{X} = \big[M, \Delta M, \Delta^2 M\big] \in \mathbb{R}^{3\times 128\times 130}, \tag{2.14}$$

де $M$ є логарифмічною мел-спектрограмою (розділ 2.2). Довший запис ділиться на $W$ вікон $\mathbf{X}^{(1)}, \dots, \mathbf{X}^{(W)}$ по 130 кадрів з кроком 65 кадрів.

*Модель оцінювання ймовірностей.* Модель $f_\theta$ є послідовним застосуванням п'яти перетворень:

$$\mathbf{p} = f_\theta(\mathbf{X}) = g\big(h_4(h_3(h_2(h_1(\mathbf{X}))))\big) \in [0;1]^K, \tag{2.15}$$

де $h_1$ є першим блоком з квадратними, тембральними та часовими фільтрами (2.8); $h_2$, $h_3$, $h_4$ є згортковими блоками з фільтрами $3\times 3$, кожен з яких містить згортку, нормалізацію, випрямлення та підвибір максимуму; $g$ є класифікатором з двох повнозв'язних шарів, який повертає ймовірності присутності $K = 11$ інструментів. Параметри $\theta$ усіх перетворень містять 656 091 значення; розміри проміжних результатів наведено в таблиці 2.2.

*Навчання.* Параметри моделі знаходяться як

$$\theta^* = \arg\min_\theta \ \frac{1}{BK}\sum_{i=1}^{B}\sum_{k=1}^{K} \ell\big(\widetilde{y}_{ik}, f_\theta(\widetilde{\mathbf{X}}_i)_k\big), \tag{2.16}$$

де $\ell(y,p) = -y\ln p - (1-y)\ln(1-p)$ є бінарною перехресною ентропією, а $(\widetilde{\mathbf{X}}_i, \widetilde{\mathbf{y}}_i)$ є прикладами пакета, половина з яких перетворена на синтетичні суміші за формулою (2.11). Суміші формуються заново на кожному кроці, а мінімізація

виконується методом Adam із кроком (1.8).

*Розпізнавання запису.* Для запису $s$ результат розпізнавання

$$\hat{y}_k = \begin{cases} 1, & \bar{S}_k \geqslant \tau^*, \\ 0, & \bar{S}_k < \tau^*, \end{cases} \qquad \bar{S}_k = \frac{S_k}{\max_j S_j}, \qquad S_k = \sum_{w=1}^{W} f_{\theta^*}\left(\mathbf{X}^{(w)}\right)_k, \tag{2.17}$$

де поріг $\tau^*$ обирається на синтетичній багатоінструментній перевірочній вибірці (розділ 2.10). Значення всіх параметрів моделі наведено в таблиці 2.3.

Таблиця 2.3 – Параметри моделі

| Параметр | Позначення | Значення |
|---|---|---|
| Частота дискретизації, Гц | $f_s$ | 22 050 |
| Довжина вікна і крок перетворення Фур'є, відліків | $N_w$, $H$ | 1024, 512 |
| Кількість мел-смуг | $F$ | 128 |
| Кількість кадрів у фрагменті (3 с) | $T$ | 130 |
| Нижня частота та смуг на октаву логарифмічної осі | $f_{\text{min}}$, $\beta$ | 32,7 Гц, 24 |
| Кількість смуг логарифмічної осі | $L$ | 201 |
| Кількість фільтрів першого шару (квадратні, тембральні, часові) | - | 16, 8, 8 |
| Розміри фільтрів першого шару | - | $3 \times 3$, $49 \times 1$, $1 \times 31$ |
| Кількість каналів згорткових блоків | - | 32, 64, 128, 256 |
| Кількість класів | $K$ | 11 |
| Імовірність змішування та межі різниці гучностей | $q$, $\gamma$ | 0,5; $\pm 6$ дБ |
| Кількість епох, розмір пакета | $E$, $B$ | 100, 32 |
| Початковий і кінцевий крок навчання | $\eta_0$, $\eta_{\text{min}}$ | $10^{-3}$, $10^{-5}$ |
| Поріг рішення | $\tau^*$ | 0,5 |
| Кількість параметрів | $\lvert\theta\rvert$ | 656 091 |

## 2.12 Висновки до розділу

У розділі сформульовано задачу багатоміткового розпізнавання музичних інструментів і розроблено математичну модель розпізнавання, що спирається на типовий конвеєр обробки сигналу (розділ 1) і включає:

а) аналітичну оцінку кількості мел-смуг на октаву, яка показує, що вертикальні фільтри сталої висоти на мел-шкалі охоплюють від однієї до п’яти октав залежно від регістру;

б) перший згортковий шар з квадратними, часовими та тембральними фільтрами, останні з яких працюють на логарифмічній частотній осі й охоплюють сталий музичний інтервал, що забезпечує однаковий опис тембру на різних висотах;

в) метод синтезу багатоінструментних сумішей у лінійній потужності з об’єднанням міток, що компенсує розбіжність між навчальними та тестовими даними;

г) спосіб вибору порогу рішення на синтетичній багатоінструментній перевірочній вибірці без використання тестових даних;

д) математичну модель розпізнавання, що описує представлення сигналу, модель оцінювання ймовірностей як послідовність блоків, навчання на синтетичних сумішах і правило розпізнавання запису.

Розглянуто також гармонічне представлення та обґрунтовано, чому воно може бути неоднозначним для багатоінструментних сумішей.

# 3 ПРОГРАМНЕ ЗАБЕЗПЕЧЕННЯ МОДЕЛІ РОЗПІЗНАВАННЯ МУЗИЧНИХ ІНСТРУМЕНТІВ

У розділі описано призначення та вимоги до програмного забезпечення, засоби реалізації, загальну архітектуру та організацію обчислень. Детальний опис окремих компонентів буде наведено в остаточній редакції роботи.

## 3.1 Призначення та вимоги

Програмне забезпечення призначене для автоматичного визначення інструментального складу звукових записів, а також для проведення досліджень: навчання та порівняння моделей і оцінювання їхньої якості.

*Функціональні вимоги:*

а) читання звукових файлів, приведення їх до одного каналу та єдиної частоти дискретизації, обчислення часово-частотного представлення;

б) навчання моделей з можливістю вибору архітектури та способу розширення навчальних даних, зокрема синтезу багатоінструментних сумішей;

в) розпізнавання інструментів у записі довільної тривалості з видачею множини присутніх інструментів та оцінок впевненості;

г) оцінювання моделей на тестовій вибірці за метриками розділу 4.3 з кількома незалежними запусками та підсумковою статистикою;

д) вибір порогу рішення на синтетичній багатоінструментній перевірочній вибірці.

*Нефункціональні вимоги:*

а) відтворюваність: фіксація початкових значень генераторів випадкових чисел і збереження конфігурацій експериментів;

б) продуктивність: розпізнавання запису тривалістю до 20 с не довше 0,1 с на одному графічному процесорі;

в) розширюваність: можливість додавання нових архітектур і способів

розширення даних без зміни решти компонентів;

г) коректність оцінювання: тестові дані не використовуються для вибору налаштувань, а перевірочна вибірка не містить фрагментів записів з навчальної.

## 3.2 Засоби реалізації

Програмне забезпечення реалізовано мовою Python 3. Для побудови та навчання нейронних мереж використано бібліотеку PyTorch [48], для обчислення спектральних представлень бібліотеку torchaudio, для читання звукових файлів soundfile, для обчислення метрик якості scikit-learn, для числових обчислень і візуалізації NumPy та Matplotlib. Обчислення виконувались на графічному процесорі.

## 3.3 Архітектура програмного забезпечення

Програмне забезпечення має багаторівневу архітектуру (рис. 3.1). Рівень представлення забезпечує взаємодію з користувачем через командний рядок та інтерактивні блокноти. Рівень бізнес-логіки містить основні модулі. Рівень доступу до даних відповідає за читання звукових файлів, кешування представлень і збереження моделей та результатів.

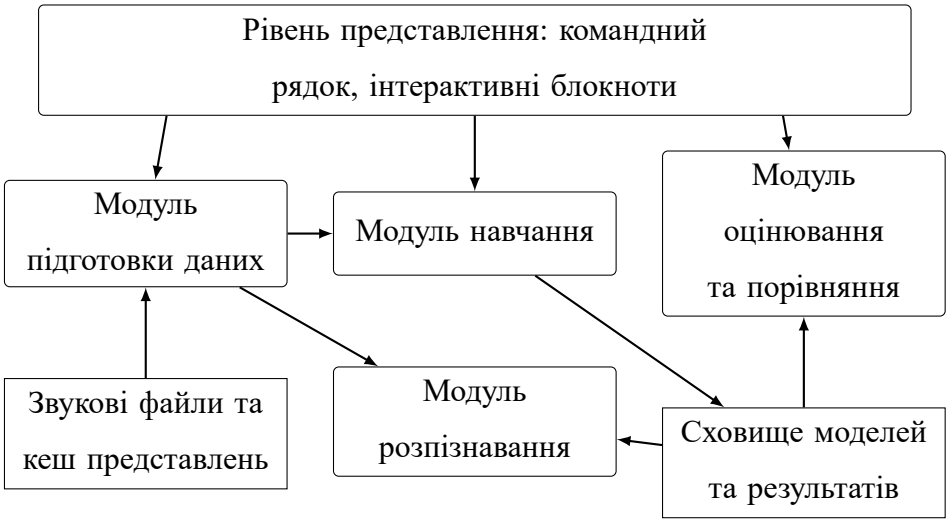



Рисунок 3.1 – Загальна архітектура програмного забезпечення

Призначення основних модулів:

– *модуль підготовки даних*: зчитування записів, перетворення на один канал, передискретизація, нормалізація, обчислення та кешування мел-спектрограм, поділ на навчальну та перевірочну вибірки за записами;

– *модуль навчання*: формування пакетів, синтез багатоінструментних сумішей, навчання моделі, збереження контрольних точок і журналів навчання;

– *модуль розпізнавання*: обробка запису ковзним вікном, агрегація оцінок і застосування порогу;

– *модуль оцінювання та порівняння*: обчислення метрик для кожного запуску, підсумкова статистика, вибір порогу, порівняння архітектур;

– *сховище моделей та результатів*: навчені моделі, кешовані представлення, конфігурації та журнали експериментів.

Моделі реалізовано як окремі класи зі спільним інтерфейсом, тому нова архітектура або новий спосіб розширення даних додається без змін у модулях навчання й оцінювання.

## 3.4 Організація обчислень

Мел-спектрограми навчальних фрагментів обчислюються один раз і зберігаються на диску. Оскільки весь навчальний набір у такому вигляді займає

близько 400 МБ, перед навчанням він повністю завантажується в пам’ять графічного процесора, а пакети формуються безпосередньо там. Синтез сумішей також виконується на графічному процесорі. Для тестових записів представлення обчислюються один раз за сеанс і використовуються для всіх моделей, що оцінюються.

Для кожного експерименту фіксуються початкові значення генераторів випадкових чисел, параметри конфігурації та результати кожного з незалежних запусків, що забезпечує відтворюваність і можливість статистичного порівняння моделей.

## 3.5 Висновки до розділу

У розділі визначено функціональні та нефункціональні вимоги до програмного забезпечення, обрано засоби реалізації та описано його загальну багаторівневу архітектуру. Модульна будова дає змогу досліджувати різні архітектури та способи розширення даних в однакових умовах, а організація обчислень забезпечує відтворюваність експериментів і необхідну продуктивність.

# 4 ВАЛІДАЦІЯ РЕЗУЛЬТАТІВ

У розділі описано навчальні та тестові дані, методику експериментів і метрики якості, наведено результати розробленої моделі, порівняння з існуючими рішеннями та аналіз внеску кожної складової моделі.

## 4.1 Опис навчальних і тестових даних

Експерименти проведено на наборі даних IRMAS [4]. Записи мають частоту дискретизації 44,1 кГц і два канали; перед обробкою їх приводять до одного каналу та частоти 22 050 Гц (розділ 2.2).

*Навчальна частина* містить фрагменти тривалістю 3 с, кожен з яких позначено одним переважаючим інструментом. Фрагменти вирізано з довших записів по кілька (як правило, по три) з кожного. У роботі використано 6101 фрагмент із 2268 записів: для шести найчисельніших класів кількість фрагментів обмежено 600, що вирівнює розподіл класів (повний набір містить 6705 фрагментів). Окрім мітки інструмента, у назві кожного файлу вказано жанр: поп-рок (2059 фрагментів), класика (1882), джаз і блюз (1723), кантрі та фолк (405), латиноамериканська музика (32); для 1628 фрагментів вказано також наявність (725) або відсутність (903) ударних.

*Тестова частина* містить 2874 фрагменти тривалістю від 5 до 20 с (у середньому 16,9 с), отримані з інших записів, ніж навчальні. Кожен фрагмент позначено одним або кількома інструментами: 1236 фрагментів мають одну мітку, 1278 по дві, 318 по три, 42 по чотири або п’ять; у середньому 1,71 мітки на фрагмент. Розподіл фрагментів за класами наведено в таблиці 4.1. Тестова частина суттєво незбалансована: голос, фортепіано та електрогітара присутні в 942–1044 фрагментах, а кларнет лише у 62.

Таблиця 4.1 – Розподіл фрагментів набору IRMAS за класами

| Інструмент | Навчальних фрагментів | Тестових фрагментів з інструментом |
|---|---|---|
| Віолончель | 388 | 111 |
| Кларнет | 505 | 62 |
| Флейта | 451 | 163 |
| Акустична гітара | 600 | 535 |
| Електрогітара | 600 | 942 |
| Орган | 600 | 361 |
| Фортепіано | 600 | 995 |
| Саксофон | 600 | 326 |
| Труба | 577 | 167 |
| Скрипка | 580 | 211 |
| Голос | 600 | 1044 |
| Разом | 6101 | 2874 фрагменти |

*Поділ на навчальну та перевірочну вибірки.* Навчальні фрагменти поділено у співвідношенні 80/20 зі стратифікацією за класами, причому поділ виконується *за записами*: усі фрагменти одного запису потрапляють до однієї вибірки. Отримано 4863 навчальні та 1238 перевірочні фрагменти. Випадковий поділ окремих фрагментів, який часто використовують на практиці, призводить до того, що 977 записів опиняються одночасно в навчальній і перевірочній вибірках. Для однієї й тієї

самої моделі це завищувало F1-міру на перевірочній вибірці з $0{,}72$ до $0{,}81$, хоча на тестовій вибірці якість залишалась незмінною в межах розкиду між запусками. Тестова вибірка використовується лише для остаточного оцінювання.

## 4.2 Методика експериментів

Для кожної конфігурації моделі виконується $R = 5$ незалежних запусків навчання з різними початковими значеннями генераторів випадкових чисел. Результати подаються у вигляді середнього значення та стандартного відхилення за запусками. Окремі допоміжні експерименти виконано з одним запуском; у таблицях вони позначені окремо, а їхні результати розглядаються як орієнтовні, оскільки розкид між запусками становить 0,002–0,009.

Розроблена модель навчається 100 епох з параметрами розділу 2.9; синтетичні суміші формуються для половини фрагментів кожного пакета з різницею гучностей у межах $\pm 6$ дБ. Поріг рішення обирається на синтетичній багатоінструментній перевірочній вибірці (розділ 2.10); тестова вибірка для вибору налаштувань не використовується.

Для порівняння в однакових умовах відтворено моделі [15] та [21]. Модель [15] навчено на фрагментах 1 с з тим самим поділом даних, у двох варіантах: 30 епох і з ранньою зупинкою за функцією втрат на перевірочній вибірці (як в оригінальній роботі). Модель [21] відтворено за описом, перерахувавши висоту фільтрів для 128 мел-смуг. Відтворені моделі оцінюються з тим самим правилом агрегації та порогом $0{,}5$.

## 4.3 Метрики якості

Нехай для класу $k$ на тестовій вибірці $TP_k$, $FP_k$, $FN_k$ позначають кількості правильно розпізнаних, хибно розпізнаних і пропущених інструментів. Точність,

повнота та F1-міра класу:

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k}, \quad F1_k = \frac{2P_k R_k}{P_k + R_k}. \tag{4.1}$$

Макроусереднена F1-міра є середнім за класами:

$$F1_{\text{макро}} = \frac{1}{K} \sum_{k=1}^{K} F1_k, \tag{4.2}$$

а мікроусереднена обчислюється за сумарними кількостями:

$$F1_{\text{мікро}} = \frac{2 \sum_k TP_k}{2 \sum_k TP_k + \sum_k FP_k + \sum_k FN_k}. \tag{4.3}$$

Основною метрикою є $F1_{\text{макро}}$, оскільки вона однаково враховує всі класи, зокрема рідкісні в тестовій вибірці; $F1_{\text{мікро}}$ відображає загальну частку правильних рішень і залежить переважно від частих класів.

## 4.4 Вибір порогу рішення

Синтетична багатоінструментна перевірочна вибірка містить 1238 сумішей (32 % з одним, 35 % з двома та 32 % з трьома джерелами; у середньому 1,89 мітки). Залежність середньої за п’ятьма запусками макроусередненої F1-міри від порогу для моделі з тембральними фільтрами на логарифмічній осі (30 епох) наведено в таблиці 4.2; для інших досліджених моделей оптимум лежить у тих самих межах. Оптимальні значення лежать на плато $0{,}40$–$0{,}50$, у межах якого якість змінюється не більше ніж на $0{,}003$, а при $\tau > 0{,}55$ помітно знижується. Тому обрано $\tau = 0{,}5$, що збігається зі значенням, використаним у роботі [15], і дає змогу коректно порівнювати результати.

Таблиця 4.2 – Макроусереднена F1-міра на синтетичній перевірочній вибірці залежно від порогу

| Поріг $\tau$ | F1 макро |
|---|---|
| 0,30 | 0,577 |
| 0,35 | 0,584 |
| 0,40 | 0,587 |
| 0,45 | 0,585 |
| 0,50 | 0,583 |
| 0,55 | 0,580 |
| 0,60 | 0,575 |
| 0,65 | 0,570 |
| 0,70 | 0,561 |

## 4.5 Аналіз отриманих результатів

Результати розробленої моделі на тестовій вибірці наведено в таблиці 4.3. Усі п’ять незалежних запусків дали макроусереднену F1-міру в межах $0{,}518$–$0{,}528$. Час розпізнавання запису тривалістю 20 с, включно з обчисленням спектрограми, становить близько 0,04 с на графічному процесорі.

Таблиця 4.3 – Результати розробленої моделі на тестовій вибірці (5 запусків, $\tau = 0{,}5$)

| Усереднення | Точність | Повнота | F1-міра |
|---|---|---|---|
| Макро | 0,592 | 0,510 | $0{,}524 \pm 0{,}004$ |
| Мікро | 0,721 | 0,535 | $0{,}614 \pm 0{,}004$ |

Результати за класами наведено в таблиці 4.4. Найкраще розпізнається голос ($F1 = 0{,}92$) та саксофон ($0{,}73$), найгірше кларнет ($0{,}21$), віолончель ($0{,}31$) та орган ($0{,}35$). Низька якість для кларнета пояснюється його рідкістю в тестовій вибірці (62 фрагменти) та схожістю тембру з іншими духовими інструментами. Для гітар, фортепіано та органу характерна висока точність за низької повноти: модель рідко помиляється, називаючи ці інструменти, але часто їх пропускає, коли вони звучать як акомпанемент.

Таблиця 4.4 – Результати за класами (середнє за 5 запусками, $\tau = 0{,}5$)

| Інструмент | Точність | Повнота | F1-міра |
|---|---|---|---|
| Віолончель | 0,288 | 0,341 | 0,312 |
| Кларнет | 0,177 | 0,274 | 0,214 |
| Флейта | 0,495 | 0,589 | 0,538 |
| Акустична гітара | 0,805 | 0,440 | 0,569 |
| Електрогітара | 0,817 | 0,355 | 0,495 |
| Орган | 0,426 | 0,291 | 0,346 |
| Фортепіано | 0,862 | 0,360 | 0,508 |
| Саксофон | 0,652 | 0,840 | 0,734 |
| Труба | 0,535 | 0,641 | 0,583 |
| Скрипка | 0,513 | 0,577 | 0,543 |
| Голос | 0,941 | 0,902 | 0,921 |

## 4.6 Порівняння з існуючими рішеннями

У таблиці 4.5 наведено опубліковані результати відомих моделей на наборі IRMAS та результати розробленої моделі. Розроблена модель перевершує опубліковані результати за обома метриками, маючи в 2,2 раза менше параметрів, ніж модель [15].

Таблиця 4.5 – Порівняння з опублікованими результатами на тестовій частині IRMAS

| Модель | Параметрів | F1 макро | F1 мікро |
|---|---|---|---|
| Ознаки та метод опорних векторів [4] | - | 0,432 | 0,503 |
| Згорткова мережа [15] | 1,45 млн | 0,503 | 0,602 |
| Одношарова мережа з музичними фільтрами [21] | 62 тис. | 0,484 | 0,559 |
| Багатошарова мережа з музичними фільтрами [21] | 743 тис. | 0,516 | 0,589 |
| Розроблена модель | 656 тис. | $0{,}524 \pm 0{,}004$ | $0{,}614 \pm 0{,}004$ |

Опубліковані результати отримано за різних методик: у роботі [15] налаштування обирались за F1-мірою без опису окремої перевірочної вибірки, у роботі [21] спосіб вибору порогу та кількість запусків не вказано. Тому моделі також відтворено й оцінено за методикою цієї роботи (табл. 4.6). В однакових умовах відтворені моделі поступаються опублікованим значенням на 0,037–0,044, що узгоджується з різницею в методиках. Розроблена модель перевершує модель [15] з ранньою зупинкою на 0,058, а модель [21] на 0,047 і має суттєво менший розкид між запусками.

Таблиця 4.6 – Порівняння за однаковою методикою (5 запусків, $\tau = 0{,}5$)

| Модель | F1 макро | F1 мікро |
|---|---|---|
| Модель [15], 30 епох | $0{,}459 \pm 0{,}021$ | $0{,}552 \pm 0{,}026$ |
| Модель [15], рання зупинка | $0{,}466 \pm 0{,}017$ | $0{,}559 \pm 0{,}023$ |
| Модель [21] | $0{,}477 \pm 0{,}006$ | $0{,}576 \pm 0{,}006$ |
| Розроблена модель | $0{,}524 \pm 0{,}004$ | $0{,}614 \pm 0{,}004$ |

## 4.7 Аналіз внеску складових моделі

Для оцінки внеску кожної складової моделі послідовно додавались до базової згорткової мережі з квадратними фільтрами (табл. 4.7).

Таблиця 4.7 – Внесок складових моделі (F1 макро на тестовій вибірці, $\tau = 0{,}5$)

| Конфігурація | Запусків | F1 макро |
|---|---|---|
| Базова мережа, квадратні фільтри | 1 | 0,480 |
| + синтетичні суміші | 5 | $0{,}504 \pm 0{,}009$ |
| + тембральні та часові фільтри на мел-осі | 5 | $0{,}506 \pm 0{,}005$ |
| тембральні фільтри перенесено на логарифмічну вісь | 5 | $0{,}504 \pm 0{,}002$ |
| + вибір максимуму в останньому блоці | 5 | $0{,}505 \pm 0{,}004$ |
| + 100 епох навчання (розроблена модель) | 5 | $0{,}524 \pm 0{,}004$ |

Найбільший внесок дають синтетичні суміші ($+0{,}024$) та довше навчання ($+0{,}019$). Перенесення тембральних фільтрів на логарифмічну вісь у цій мережі майже не змінює середнього значення, але вдвічі зменшує розкид між запусками. На моделі [21], де тембральні фільтри займають більшу частину першого шару, перенесення на логарифмічну вісь дає стабільне покращення: макроусереднена F1-міра зростає з $0{,}475 \pm 0{,}004$ до $0{,}485 \pm 0{,}002$, причому кожен із п'яти запусків з логарифмічною віссю кращий за кожен запуск без неї.

*Тривалість навчання.* Без синтетичних сумішей збільшення кількості епох з 30 до 60 погіршувало якість через перенавчання. Із сумішами результат зростає до 100 епох (табл. 4.8): оскільки суміші формуються заново на кожній епосі, модель повільніше запам'ятовує навчальні фрагменти.

Таблиця 4.8 – Залежність якості від кількості епох (розроблена модель)

| Епох | 30 | 60 | 100 | 150 |
|---|---|---|---|---|
| Запусків | 5 | 1 | 5 | 1 |
| F1 макро | $0{,}505 \pm 0{,}004$ | 0,504 | $0{,}524 \pm 0{,}004$ | 0,517 |

*Гармонічне представлення та синтетичні суміші.* У таблиці 4.9 наведено результати базової мережі з гармонічним накладанням каналів на частотах $f$, $2f$, $4f$, $8f$ (розділ 2.7) та без нього, навченої з сумішами та без них. Варіант з обертонами $h = 1, \ldots, 5$ без сумішей дав близьку якість (0,491, один запуск). Без сумішей гармонічне представлення покращує якість на 0,019, а з сумішами погіршує на 0,026. Канал м'якого мінімуму за обертонами разом із сумішами також знижує якість ($0{,}492 \pm 0{,}003$ проти $0{,}506 \pm 0{,}005$ для тієї самої мережі без нього). Це підтверджує висновок розділу 2.7: у суміші енергія на частотах обертонів може належати іншому інструменту, і гармонічні канали стають неоднозначними.

Таблиця 4.9 – Вплив гармонічного представлення залежно від синтетичних сумішей (F1 макро)

| | Без сумішей | Із сумішами |
|---|---|---|
| Без гармонічного представлення | 0,480* | $0{,}504 \pm 0{,}009$ |
| З гармонічним представленням | 0,499* | 0,478* |
| * один запуск | | |

*Інші досліджені варіанти* не покращили результат: фільтри кількох висот (пів-, дві та чотири октави) дали $0{,}501 \pm 0{,}005$; суміші до трьох джерел для 80 % фрагментів дали $0{,}488 \pm 0{,}004$ (модель починає розпізнавати зайві інструменти); змішування лише в межах одного жанру дало 0,497, а додатковий канал частотної позиції 0,499 (по одному запуску).

## 4.8 Висновки до розділу

Проведено валідацію розробленої моделі на наборі даних IRMAS за відтворюваною методикою: перевірочна вибірка сформована без перетину записів з навчальною, поріг рішення обрано на синтетичній багатоінструментній перевірочній вибірці, результати усереднено за п’ятьма незалежними запусками.

Розроблена модель досягає макроусередненої F1-міри $0{,}524 \pm 0{,}004$ і мікроусередненої $0{,}614 \pm 0{,}004$, що перевищує опубліковані результати відомих згорткових моделей ($0{,}503$ і $0{,}516$ за макроусередненою мірою) за 656 тис. параметрів. В однакових умовах вона перевершує відтворені моделі [15] і [21] на 0,058 і 0,047 відповідно.

Аналіз складових показав, що основний внесок дають синтетичні багатоінструментні суміші та довше навчання, яке вони уможливлюють; перенесення тембральних фільтрів на логарифмічну вісь підвищує стабільність моделі та

покращує модель [21]; явне гармонічне представлення корисне лише без сумішей. Найнижча якість спостерігається для рідкісних у тестовій вибірці інструментів (кларнет, віолончель) та для інструментів акомпанементу, які модель часто пропускає.

# ВИСНОВКИ

У роботі розв’язано задачу підвищення точності розпізнавання музичних інструментів у багатоінструментних звукових записах. Основні результати роботи такі.

а) Розроблено метод навчання на синтетичних багатоінструментних сумішах, що формуються додаванням навчальних фрагментів у лінійній потужності з об’єднанням міток, та модель згорткової нейронної мережі з музично обґрунтованими фільтрами (656 тис. параметрів). Розроблено програмне забезпечення та відтворювану методику оцінювання, у якій перевірочна вибірка не містить частин навчальних записів, а поріг рішення обирається без використання тестових даних.

б) На тестовій частині набору IRMAS розроблена модель досягає макроусередненої F1-міри $0{,}524 \pm 0{,}004$ та мікроусередненої $0{,}614 \pm 0{,}004$ (середнє за п’ятьма запусками), що перевищує опубліковані результати відомих згорткових моделей ($0{,}503$ та $0{,}516$), маючи в 2,2 раза менше параметрів, ніж найпоширеніша з них. В однакових умовах оцінювання вона перевершує відтворені відомі моделі на $0{,}047$–$0{,}058$.

в) Встановлено, що основний внесок дають синтетичні суміші (з $0{,}480$ до $0{,}504$) та довше навчання, яке вони уможливлюють (до $0{,}524$), а явне гармонічне представлення корисне лише без сумішей: воно підвищує F1-міру з $0{,}480$ до $0{,}499$, але із сумішами знижує її з $0{,}504$ до $0{,}478$.

Отримані результати можуть бути використані для автоматичної каталогізації та пошуку в музичних колекціях.

# ПЕРЕЛІК ПОСИЛАНЬ

1. Essid S., Richard G., David B. Instrument recognition in polyphonic music based on automatic taxonomies. *IEEE Transactions on Audio, Speech, and Language Processing*. 2006. Vol. 14, No. 1. P. 68–80. DOI: 10.1109/TSA.2005.860351.

2. Fuhrmann F. *Automatic musical instrument recognition from polyphonic music audio signals*: PhD thesis. Barcelona: Universitat Pompeu Fabra, 2012.

3. Tsoumakas G., Katakis I. Multi-label classification: an overview. *International Journal of Data Warehousing and Mining*. 2007. Vol. 3, No. 3. P. 1–13. DOI: 10.4018/jdwm.2007070101.

4. Bosch J. J., Janer J., Fuhrmann F., Herrera P. A comparison of sound segregation techniques for predominant instrument recognition in musical audio signals. *Proceedings of the 13th International Society for Music Information Retrieval Conference (ISMIR)*. Porto, 2012. P. 559–564.

5. Cyanite. Music tagging. URL: https://cyanite.ai/music-tagging/ (дата звернення: 13.10.2026).

6. SoundCloud acquires AI music startup, Musiio, to improve music discovery. *MusicTech*. 2022. URL: https://musictech.com/news/soundcloud-acquires-ai-music-startup-musiio-improve-music-discovery/ (дата звернення: 13.10.2026).

7. iZotope introduces Neutron intelligent mixing assistant software. *audioXpress*. URL: https://audioxpress.com/news/izotope-introduces-neutron-intelligent-mixing-assistant-software (дата звернення: 13.10.2026).

8. Logic Pro update adds guitar and piano stems, new sound packs, and can even recover tracks you didn’t save. *9to5Mac*. 2025. URL: https://9to5mac.com/2025/05/28/logic-pro-update-adds-guitar-and-piano-stems-new-sound-packs-and-can-even-recover-tracks-you-didnt-save/ (дата звернення: 13.10.2026).

9. Humphrey E. J., Durand S., McFee B. OpenMIC-2018: an open data-set for multiple instrument recognition. *Proceedings of the 19th International Society for Music Information Retrieval Conference (ISMIR)*. Paris, 2018. P. 438–444.

10. Engel J., Resnick C., Roberts A., Dieleman S., Norouzi M., Eck D., Simonyan K. Neural audio synthesis of musical notes with WaveNet autoencoders. *Proceedings of the 34th*

*International Conference on Machine Learning (ICML)*. Sydney, 2017. P. 1068–1077.

11. Sokolova M., Lapalme G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*. 2009. Vol. 45, No. 4. P. 427–437. DOI: 10.1016/j.ipm.2009.03.002.

12. Müller M. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Cham: Springer, 2015. DOI: 10.1007/978-3-319-21945-5.

13. Herrera-Boyer P., Peeters G., Dubnov S. Automatic classification of musical instrument sounds. *Journal of New Music Research*. 2003. Vol. 32, No. 1. P. 3–21. DOI: 10.1076/jnmr.32.1.3.16798.

14. Choi K., Fazekas G., Cho K., Sandler M. A tutorial on deep learning for music information retrieval. 2017. arXiv:1709.04396.

15. Han Y., Kim J., Lee K. Deep convolutional neural networks for predominant instrument recognition in polyphonic music. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*. 2017. Vol. 25, No. 1. P. 208–221. DOI: 10.1109/TASLP.2016.2632307.

16. Oppenheim A. V., Schafer R. W. *Discrete-Time Signal Processing*. 3rd ed. Upper Saddle River: Pearson, 2010.

17. Stevens S. S., Volkmann J., Newman E. B. A scale for the measurement of the psychological magnitude pitch. *The Journal of the Acoustical Society of America*. 1937. Vol. 8, No. 3. P. 185–190. DOI: 10.1121/1.1915893.

18. O'Shaughnessy D. *Speech Communication: Human and Machine*. Reading, MA: Addison-Wesley, 1987.

19. Davis S., Mermelstein P. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. 1980. Vol. 28, No. 4. P. 357–366. DOI: 10.1109/TASSP.1980.1163420.

20. Furui S. Speaker-independent isolated word recognition using dynamic features of speech spectrum. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. 1986. Vol. 34, No. 1. P. 52–59. DOI: 10.1109/TASSP.1986.1164788.

21. Pons J., Slizovskaia O., Gong R., Gómez E., Serra X. Timbre analysis of music audio signals with convolutional neural networks. *Proceedings of the 25th European Signal Processing Conference (EUSIPCO)*. Kos, 2017. P. 2744–2748. DOI: 10.23919/EUSIPCO.2017.8081710.

22. Peeters G. *A large set of audio features for sound description (similarity and*

*classification) in the CUIDADO project*: technical report, version 1.0. Paris: IRCAM, 2004.

23. Marques J., Moreno P. J. *A study of musical instrument classification using Gaussian mixture models and support vector machines*: technical report CRL 99/4. Cambridge, MA: Compaq Cambridge Research Laboratory, 1999.

24. Agostini G., Longari M., Pollastri E. Musical instrument timbres classification with spectral features. *EURASIP Journal on Applied Signal Processing*. 2003. Vol. 2003, No. 1. P. 5–14. DOI: 10.1155/S1110865703210118.

25. Eronen A., Klapuri A. Musical instrument recognition using cepstral coefficients and temporal features. *Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*. Istanbul, 2000. Vol. 2. P. II-753–II-756. DOI: 10.1109/ICASSP.2000.859069.

26. Kitahara T., Goto M., Komatani K., Ogata T., Okuno H. G. Instrument identification in polyphonic music: feature weighting to minimize influence of sound overlaps. *EURASIP Journal on Advances in Signal Processing*. 2007. Vol. 2007. Article ID 51979. DOI: 10.1155/2007/51979.

27. LeCun Y., Bengio Y., Hinton G. Deep learning. *Nature*. 2015. Vol. 521, No. 7553. P. 436–444. DOI: 10.1038/nature14539.

28. Goodfellow I., Bengio Y., Courville A. *Deep Learning*. Cambridge, MA: MIT Press, 2016.

29. Li P., Qian J., Wang T. Automatic instrument recognition in polyphonic music using convolutional neural networks. 2015. arXiv:1511.05520.

30. Lostanlen V., Cella C.-E. Deep convolutional networks on the pitch spiral for musical instrument recognition. *Proceedings of the 17th International Society for Music Information Retrieval Conference (ISMIR)*. New York, 2016. P. 612–618.

31. Hung Y.-N., Yang Y.-H. Frame-level instrument recognition by timbre and pitch. *Proceedings of the 19th International Society for Music Information Retrieval Conference (ISMIR)*. Paris, 2018. P. 135–142.

32. Gururani S., Sharma M., Lerch A. An attention mechanism for musical instrument recognition. *Proceedings of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. Delft, 2019. P. 83–90.

33. Gemmeke J. F., Ellis D. P. W., Freedman D., Jansen A., Lawrence W., Moore R. C., Plakal M., Ritter M. Audio Set: an ontology and human-labeled dataset for audio events. *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. New Orleans, 2017. P. 776–780. DOI:

10.1109/ICASSP.2017.7952261.

34. Hershey S., Chaudhuri S., Ellis D. P. W. et al. CNN architectures for large-scale audio classification. *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. New Orleans, 2017. P. 131–135. DOI: 10.1109/ICASSP.2017.7952132.

35. Kong Q., Cao Y., Iqbal T., Wang Y., Wang W., Plumbley M. D. PANNs: large-scale pretrained audio neural networks for audio pattern recognition. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*. 2020. Vol. 28. P. 2880–2894. DOI: 10.1109/TASLP.2020.3030497.

36. Kingma D. P., Ba J. Adam: a method for stochastic optimization. *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*. San Diego, 2015.

37. Loshchilov I., Hutter F. SGDR: stochastic gradient descent with warm restarts. *Proceedings of the 5th International Conference on Learning Representations (ICLR)*. Toulon, 2017.

38. Ioffe S., Szegedy C. Batch normalization: accelerating deep network training by reducing internal covariate shift. *Proceedings of the 32nd International Conference on Machine Learning (ICML)*. Lille, 2015. P. 448–456.

39. Srivastava N., Hinton G., Krizhevsky A., Sutskever I., Salakhutdinov R. Dropout: a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*. 2014. Vol. 15. P. 1929–1958.

40. Brown J. C. Calculation of a constant Q spectral transform. *The Journal of the Acoustical Society of America*. 1991. Vol. 89, No. 1. P. 425–434. DOI: 10.1121/1.400476.

41. Bittner R. M., McFee B., Salamon J., Li P., Bello J. P. Deep salience representations for F0 estimation in polyphonic music. *Proceedings of the 18th International Society for Music Information Retrieval Conference (ISMIR)*. Suzhou, 2017. P. 63–70.

42. Won M., Chun S., Nieto O., Serra X. Data-driven harmonic filters for audio representation learning. *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Barcelona, 2020. P. 536–540. DOI: 10.1109/ICASSP40776.2020.9053669.

43. FitzGerald D. Harmonic/percussive separation using median filtering. *Proceedings of the 13th International Conference on Digital Audio Effects (DAFx)*. Graz, 2010.

44. Park D. S., Chan W., Zhang Y., Chiu C.-C., Zoph B., Cubuk E. D., Le Q. V. SpecAugment: a simple data augmentation method for automatic speech recognition. *Proceedings of Interspeech*. Graz, 2019. P. 2613–2617. DOI: 10.21437/Interspeech.2019-

2680.

45. Schlüter J., Grill T. Exploring data augmentation for improved singing voice detection with neural networks. *Proceedings of the 16th International Society for Music Information Retrieval Conference (ISMIR)*. Málaga, 2015. P. 121–126.

46. Zhang H., Cisse M., Dauphin Y. N., Lopez-Paz D. mixup: beyond empirical risk minimization. *Proceedings of the 6th International Conference on Learning Representations (ICLR)*. Vancouver, 2018.

47. Kratimenos A., Avramidis K., Garoufis C., Zlatintsi A., Maragos P. Augmentation methods on monophonic audio for instrument classification in polyphonic music. *Proceedings of the 28th European Signal Processing Conference (EUSIPCO 2020)*. Amsterdam, 2021. P. 156–160. DOI: 10.23919/Eusipco47968.2020.9287745.

48. Paszke A., Gross S., Massa F. et al. PyTorch: an imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems 32 (NeurIPS)*. Vancouver, 2019. P. 8024–8035.

# 5 НАУКОВА СТАТТЯ ТА АПРОБАЦІЯ РЕЗУЛЬТАТІВ

Основні результати дослідження викладено в тезах доповіді «Модель розпізнавання музичних інструментів у багатоінструментних звукових записах» (автори: В. М. Лось, І. Ю. Омельченко), підготовлених для апробації на науковій конференції ПМК-2026. Текст тез наведено на наступних сторінках.

УДК 004.85:534.3

**Д-р фіз.-мат. наук, проф. Лось В. М., магістрант Омельченко І. Ю.**

**Національний технічний університет України**
**«Київський політехнічний інститут імені Ігоря Сікорського»**

# МОДЕЛЬ РОЗПІЗНАВАННЯ МУЗИЧНИХ ІНСТРУМЕНТІВ У БАГАТОІНСТРУМЕНТНИХ ЗВУКОВИХ ЗАПИСАХ

## Abstract

**Valerii Los, prof., Dr. Sci.; Ivan Omelchenko, master student**

***A MODEL FOR MUSICAL INSTRUMENT RECOGNITION IN MULTI-INSTRUMENT AUDIO RECORDINGS***

*The paper considers automatic recognition of musical instruments in multi-instrument audio recordings. A convolutional neural network is proposed whose first layer combines square, temporal and timbral filters, the latter applied on a logarithmic frequency axis so that each filter covers a constant musical interval regardless of pitch. To reduce the mismatch between single-instrument training data and multi-instrument test data, the model is trained on synthetic mixtures obtained by adding training excerpts in linear power. On the IRMAS dataset, with a validation split grouped by recordings and a decision threshold chosen without test data, the model achieves a macro-averaged F1-score of 0.524 ± 0.004 and a micro-averaged F1-score of 0.614 ± 0.004 over five runs, exceeding the published results of known convolutional models with 656 thousand parameters.*

### Вступ

Інформація про інструментальний склад звукових записів потрібна для каталогізації та пошуку в музичних колекціях, побудови рекомендаційних систем і музикознавчого аналізу. Ручне анотування великих колекцій потребує значних витрат часу, тому актуальною є задача автоматичного розпізнавання музичних інструментів.

Найскладнішим є випадок багатоінструментних записів, у яких кілька інструментів звучать одночасно. Найкращі опубліковані згорткові моделі на стандартному наборі даних IRMAS досягають макроусередненої F1-міри 0,503 [1] та 0,516 [2], проте навчаються на фрагментах з одним інструментом, а застосовуються до записів з кількома інструментами.

### Постановка задачі

Метою роботи є підвищення точності розпізнавання музичних інструментів у багатоінструментних звукових записах шляхом розроблення

моделі згорткової нейронної мережі з музично обґрунтованими фільтрами та методу її навчання на синтетичних сумішах записів.

Задача формулюється як багатоміткова класифікація: для запису потрібно визначити вектор $\hat{y} \in \{0,1\}^K$, у якому одиниця відповідає присутньому інструменту, $K = 11$. Навчальні фрагменти набору IRMAS тривалістю 3 с позначено одним переважаючим інструментом, а тестові записи тривалістю 5–20 с одним або кількома [3].

**Тембральні фільтри на логарифмічній частотній осі**

Вхідними даними моделі є логарифмічна мел-спектрограма з 128 смугами та її часові похідні. Для музично обґрунтованих фільтрів [2] важливо, скільки смуг припадає на одну октаву. Номер мел-смуги для частоти $f$ дорівнює $\mu(f)/\Delta\mu$, де $\mu(f) = 2595\log_{10}(1 + f/700)$, тому кількість смуг в октаві $[f;\ 2f]$ становить

$$N_{\text{окт}}(f) = \frac{2595}{\Delta\mu} \cdot \log_{10}\frac{700 + 2f}{700 + f},$$

де $\Delta\mu \approx 24{,}6$ мел є кроком мел-шкали. Для частот 55–110 Гц октава займає 3 смуги, а для 3,5–7 кГц 28 смуг, тобто вертикальний фільтр сталої висоти охоплює від однієї до п’яти октав залежно від регістру.

Тому тембральні фільтри виконуються на логарифмічній частотній осі з частотами

$$\varphi_\ell = f_{\min} \cdot 2^{\ell/\beta},$$

де $f_{\min} = 32{,}7$ Гц, $\beta = 24$ смуги на октаву; мел-спектрограма переноситься на цю вісь лінійною інтерполяцією. На такій осі зміна висоти ноти на $d$ півтонів зсуває весь набір обертонів на $\beta d/12$ смуг без зміни форми, тож фільтр висотою дві октави описує тембр однаково на будь-якій висоті. На мел-осі цей зсув різний для різних обертонів, і така властивість не виконується.

**Архітектура моделі**

Вхідними даними моделі є тензор $X = [M, \Delta M, \Delta^2 M]$ розміром 3×128×130, що відповідає фрагменту тривалістю 3 с. Перший шар містить три паралельні групи фільтрів, форма яких відповідає складовим тембру [2]:

$$Z = [W_{\square} * X, \qquad Q(W_{\downarrow} * PX), \qquad W_{\rightarrow} * X],$$

де $*$ означає згортку; $W_{\square}$ є 16 квадратними фільтрами 3×3 для локальних деталей; $W_{\downarrow}$ є 8 тембральними фільтрами висотою 49 смуг логарифмічної осі

(рівно дві октави), що відображають спектральну обвідну; $W_{\rightarrow}$ є 8 часовими фільтрами 1×31 (близько 0,7 с), що відображають атаку та згасання звуку; $P$ і $Q$ є матрицями лінійної інтерполяції, що переносять спектрограму на логарифмічну вісь і повертають відгуки фільтрів на мел-сітку.

Далі слідують три згорткові блоки з фільтрами 3×3, кожен з яких містить згортку, пакетну нормалізацію, випрямлення та підвибір максимуму. В останньому блоці використовується адаптивний вибір максимуму, який, на відміну від усереднення, зберігає сильну реакцію на інструмент, що звучить лише частину фрагмента. Класифікатор з двох повнозв'язних шарів повертає 11 незалежних ймовірностей присутності інструментів через сигмоїдну функцію. Архітектуру наведено в таблиці 1; модель має 656 тис. параметрів.

Таблиця 1.

Архітектура моделі

| Блок | Операції | Вихід |
|---|---|---|
| Вхід | мел-спектрограма та її похідні | 3×128×130 |
| Блок 1 | перший шар, нормалізація, випрямлення, підвибір | 32×64×65 |
| Блок 2 | згортка 3×3, нормалізація, випрямлення, підвибір | 64×32×32 |
| Блок 3 | згортка 3×3, нормалізація, випрямлення, підвибір | 128×16×16 |
| Блок 4 | згортка 3×3, нормалізація, випрямлення, адапт. максимум | 256×2×2 |
| Класифікатор | повнозв'язні шари 1024→256→11, сигмоїда | 11 |

**Навчання на синтетичних сумішах**

Щоб під час навчання модель бачила кілька інструментів одночасно, половина фрагментів кожного пакета змішується з іншим фрагментом. Оскільки звуки додаються в лінійній потужності, суміш логарифмічних спектрограм і її мітка обчислюються як

$$\widetilde{M}_i = \ln(e^{M_i} + g_i e^{M_{\pi(i)}}), \quad \tilde{y}_i = y_i \vee y_{\pi(i)},$$

де $\pi$ є випадковою перестановкою пакета, $g_i$ задає випадкову різницю гучностей у межах ±6 дБ, а мітка суміші є об'єднанням міток. На відміну від змішування прикладів [4], така суміш відповідає фізичному додаванню звуків, а мітки залишаються двійковими. Суміші формуються заново на кожній епосі, тож модель бачить нові комбінації інструментів і повільніше перенавчається. Модель навчається 100 епох мінімізацією бінарної перехресної ентропії методом Adam з косинусним зменшенням кроку навчання.

**Розпізнавання запису та вибір порогу**

Запис довільної тривалості обробляється ковзним вікном 3 с з кроком 1,5 с. Для вікон $w = 1, \dots, W$ модель повертає ймовірності $p^{(w)}$, які агрегуються підсумовуванням з нормуванням на максимум [1]:

$$S_k = \sum_{w=1}^{W} p_k^{(w)}, \quad \overline{S}_k = \frac{S_k}{\max\limits_j S_j},$$

а рішення про присутність інструмента приймається за порогом:

$$\hat{y}_k = \begin{cases} 1, & \overline{S}_k \geq \tau, \\ 0, & \overline{S}_k < \tau, \end{cases}$$

Поріг не можна обирати на тестових даних, а звичайна перевірочна вибірка містить по одному інструменту і схиляє до порогу, що пригнічує другорядні інструменти. Тому поріг обирається на синтетичній багатоінструментній перевірочній вибірці, у якій кожен перевірочний фрагмент змішано з 0–2 фрагментами інших записів. Найкращі значення лежать на плато 0,40–0,50, і обрано поріг 0,5.

**Результати експериментальних досліджень**

Експерименти проведено на наборі даних IRMAS [3]. Перевірочну вибірку сформовано за записами, щоб фрагменти одного запису не потрапляли одночасно до навчальної та перевірочної вибірок: випадковий поділ фрагментів завищує F1-міру на перевірочній вибірці з 0,72 до 0,81. Результати усереднено за п’ятьма незалежними запусками. Порівняння з існуючими рішеннями наведено в таблиці 2.

Таблиця 2.

Порівняння з існуючими рішеннями на тестовій частині IRMAS

| Модель | Параметрів | F1 макро | F1 мікро |
|---|---|---|---|
| Модель Хана та ін. [1] | 1,45 млн | 0,503 | 0,602 |
| Модель Понса та ін. [2] | 743 тис. | 0,516 | 0,589 |
| Розроблена модель | 656 тис. | 0,524 ± 0,004 | 0,614 ± 0,004 |

Розроблена модель перевершує обидві відомі моделі за макро- та мікроусередненою F1-мірою, маючи в 2,2 раза менше параметрів, ніж модель [1]. Найкраще розпізнаються голос (F1-міра 0,92) та саксофон (0,73), найгірше кларнет (0,21) і віолончель (0,31), які рідко трапляються в тестовій вибірці.

Найбільший внесок дають синтетичні суміші (з 0,480 до 0,504) та довше навчання, яке вони уможливлюють (до 0,524). Встановлено також, що явне гармонічне представлення спектра [5] покращує якість при навчанні без сумішей (з 0,480 до 0,499), але погіршує її при навчанні на сумішах (з 0,504 до 0,478), оскільки в суміші енергія на частотах обертонів може належати іншому інструменту.

**Висновки**

Розроблено модель згорткової нейронної мережі, у якій тембральні фільтри працюють на логарифмічній частотній осі й охоплюють сталий музичний інтервал, та метод її навчання на синтетичних багатоінструментних сумішах. На наборі даних IRMAS модель досягає макроусередненої F1-міри 0,524 ± 0,004 та мікроусередненої 0,614 ± 0,004, перевищуючи опубліковані результати відомих згорткових моделей за меншої кількості параметрів.

Подальші дослідження передбачають навчання на повній версії набору IRMAS та підвищення якості розпізнавання інструментів акомпанементу і рідкісних класів.

**Література**

1. Han Y., Kim J., Lee K. Deep convolutional neural networks for predominant instrument recognition in polyphonic music. IEEE/ACM Transactions on Audio, Speech, and Language Processing. 2017. Vol. 25, No. 1. P. 208–221.

2. Pons J., Slizovskaia O., Gong R., Gómez E., Serra X. Timbre analysis of music audio signals with convolutional neural networks. Proceedings of the 25th European Signal Processing Conference (EUSIPCO). Kos, 2017. P. 2744–2748.

3. Bosch J. J., Janer J., Fuhrmann F., Herrera P. A comparison of sound segregation techniques for predominant instrument recognition in musical audio signals. Proceedings of the 13th International Society for Music Information Retrieval Conference (ISMIR). Porto, 2012. P. 559–564.

4. Zhang H., Cisse M., Dauphin Y. N., Lopez-Paz D. mixup: beyond empirical risk minimization. Proceedings of the 6th International Conference on Learning Representations (ICLR). Vancouver, 2018.

5. Bittner R. M., McFee B., Salamon J., Li P., Bello J. P. Deep salience representations for F0 estimation in polyphonic music. Proceedings of the 18th International Society for Music Information Retrieval Conference (ISMIR). Suzhou, 2017. P. 63–70.